

Statistical Tests

Stefan Laszlo

2025-01-15

English version below

disclaimer: Da in meinen Gruppen einige Unklarheiten aufgetreten sind, was die Unterschiede der in der VO bzw. UE behandelten statistischen Tests anbelangt bzw. wann welcher anzuwenden ist, habe ich mir erlaubt, hier eine kurze Auflistung und Erklärung zu liefern. (bis VO_10) Dabei möchte ich allerdings betonen, dass der Anspruch dieses Dokuments keinesfalls Vollständigkeit sein kann, sondern nur soweit die Materie behandelt, als das es für das Verständnis von VO und UE sinnvoll ist. Falls es Unklarheiten oder Rückfragen gibt, bin ich unter stefan.laszlo@tuwien.ac.at erreichbar.

Prinzipiell überprüfen die bis dato betrachteten Test die Position eines Lageparameters - in unserem Fall dem Mittelwert μ . Die Null-Hypothese - Annahme über Mittelwert - wird dabei gegen die Alternativ-Hypothese zu einem gewissen Signifikanzniveau α getestet. bspw:

$$H_0: \mu = \mu_0$$

$$H_1: \mu \neq \mu_0$$

In diesem konkreten Fall würde man von einem zweiseitigen Test sprechen, und die rejection region wird beidseits gebildet. Andere Varianten sind einseitige Test, die den Vorlesungsunterlagen entnommen werden können. In vielen Fällen entspricht H_1 der Verneinung von H_0 , also eine Partition des Parameterraumes. Allerdings muss das nicht zwingend so sein und hängt von dem zu testenden Kontext ab. Immer jedoch sind die Parameterbereiche unter den beiden Hypothesen disjunkt zueinander.

Nun möchte ich mich dem wesentlichen Aspekt dieser Ausarbeitung widmen und die grundlegende Unterscheidung von one- und two-sample Tests erklären.

one-sample Test

Gegeben ist hier **eine** Folge an Beobachtungen $x_1, \dots, x_n$, das sample, was einer Realisierung von iid. Zufallsvariablen $X_1, \dots, X_n$ entspricht. Diesen Zufallsvariablen unterstellt man eine gewisse Verteilung mit Mittelwert μ_0 . Ziel des statistischen Tests ist es nun mittels des empirischen Mittelwerts $\bar{x}$ diese Annahme über den Erwartungswert der Grundgesamtheit zu validieren oder abzulehnen.

one-sample z-test

Gegeben sei nun wieder die Folge an iid. Zufallsvariablen $X_1, \dots, X_n$, für die gilt, $X \sim N(\mu_x, \sigma_x^2)$. Entscheidend ist, dass in diesem Fall die Standardabweichung als **bekannt** vorausgesetzt wird und unter der Null-Hypothese $\mu_x = \mu_0$, die Teststatistik $Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$ somit standardnormalverteilt ist. Nun geht man auf die Prüfgröße $z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$ über, und mittels der Standardnormalverteilung trifft man die Testentscheidung. H_0 verwerfen, falls $z \in R$ und ansonsten beibehalten.

Bem.: Die Annahme, dass X zwingendermaßen normalverteilt ist, kann für hinreichend große Stichproben (als Faustregel soll n mind. 30 sein) vernachlässigt werden, denn der Zentrale Grenzwertsatz liefert uns dennoch, dass $Z \sim_{H_0} N(0, 1)$.

one-sample t-test

Die Ausgangslage ist nahezu dieselbe. Wiederum sind normalverteilte iid. Zufallsvariablen gegeben, allerdings nun mit dem Unterschied, dass die Standardabweichung **unbekannt** ist. Naheliegenderweise wird diese durch die empirische Standardabweichung der Stichprobe geschätzt, was unter der Null-Hypothese $\mu_x = \mu_0$ dazu führt, dass die Teststatistik $T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$ nicht standardnormal-, sondern t-verteilt ist, mit $n - 1$ Freiheitsgraden. Das Auswerten des Tests funktioniert völlig analog. Erneut, geht man auf die Prüfgröße $t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$ über und bestimmt mittels der $t(n - 1)$ Verteilung die rejection region. H_0 verwerfen, falls $t \in R$ und ansonsten beibehalten.

Bem.: Die Annahme, dass X zwingendermaßen normalverteilt ist, kann für hinreichend große Stichproben (als Faustregel soll n mind. 30 sein) vernachlässigt werden, denn der Zentrale Grenzwertsatz liefert uns dann, dass $T \sim_{H_0} N(0, 1)$. Für die Bestimmung von R genügt es somit für große n auf die Standardnormalverteilung zurückzugreifen.

two-sample t-test

Gegeben sind hier **zwei** unabhängige (**der abhängige Fall ist nicht Teil des VO Stoffs**) Folgen an Beobachtungen $x_1, \dots, x_n$ sowie $y_1, \dots, y_m$, die samples, die jeweils einer Realisierung von iid. Zufallsvariablen $X_1, \dots, X_n$ mit $X \sim N(\mu_1, \sigma_1^2)$ bzw. $Y_1, \dots, Y_m$ mit $Y \sim N(\mu_2, \sigma_2^2)$ entsprechen. Die Varianzen σ_1^2 und σ_2^2 sind **unbekannt**. (ansonsten wären wir im setting des two-sample z-test) Im Rahmen der Null-Hypothese, wird eine Annahme über die Lage der Mittelwerte μ_1 und μ_2 getroffen. Bspw. hier der Fall des zweiseitigen Tests:

$$H_0: \mu_1 - \mu_2 = d_0$$

$$H_1: \mu_1 - \mu_2 \neq d_0$$

Sehr oft wird $d_0 = 0$ gesetzt - um Gleichheit von μ_1 und μ_2 zu überprüfen. Ziel des statistischen Tests ist es jedenfalls, mittels der empirischen Mittelwerte $\bar{x}$ und $\bar{y}$ diese Annahme über die Erwartungswerte der Grundgesamtheiten zu einem gewissen Signifikanzniveau α zu validieren oder abzulehnen. Die Art des konkreten Tests ist nun abhängig davon, ob die Varianzen σ_1^2 und σ_2^2 gleich sind oder nicht. Wir unterscheiden:

Welch Test

In diesem Fall werden die Varianzen σ_1^2 und σ_2^2 als **ungleich** angenommen. Die Teststatistik hat unter der Null-Hypothese folgende Gestalt:

$$T = \frac{(\bar{Y} - \bar{X}) - d_0}{\sqrt{\frac{S_1^2}{n} + \frac{S_2^2}{m}}}$$

und es gilt näherungsweise, dass $T \sim t(\nu)$ mit

$$\nu = \frac{\left(\frac{s_1^2}{n} + \frac{s_2^2}{m}\right)^2}{\frac{1}{n-1} \left(\frac{s_1^2}{n}\right)^2 + \frac{1}{m-1} \left(\frac{s_2^2}{m}\right)^2}$$

In obiger Darstellung bezeichnet S_1 die empirische Standardabweichung von σ_1 und analog für S_2 . Weiters ist s_1 die Auswertung von S_1 basierend auf dem sample $x_1, \dots, x_n$ und auch hier wieder analog für s_2 . Das Auswerten des Tests funktioniert wie zuvor. Durch Übergehen auf die Prüfgröße $t = \frac{(\bar{y} - \bar{x}) - d_0}{\sqrt{s_1^2/n + s_2^2/m}}$ und bestimmen der rejection region (für den zweiseitigen Test $1 - \alpha/2$ Quantil der $t(\nu)$ Verteilung) kann die Testentscheidung getroffen werden. H_0 verwerfen, falls $t \in R$ und ansonsten beibehalten.

Bem.: Die Annahme, dass X und Y zwingendermaßen normalverteilt sind, kann für hinreichend große Stichproben (als Faustregel sollen n **und** m mind. 50 sein) vernachlässigt werden, denn der Zentrale Grenzwertsatz liefert uns dann, dass $T \sim_{H_0} N(0, 1)$. Für die Bestimmung von R genügt es somit für große n und m auf die Standardnormalverteilung zurückzugreifen.

Student t-Test

In diesem Fall werden die Varianzen σ_1^2 und σ_2^2 als **gleich** angenommen. Die Teststatistik hat unter der Null-Hypothese folgende Gestalt:

$$T = \frac{(\bar{Y} - \bar{X}) - d_0}{\sqrt{\frac{1}{m} + \frac{1}{n}} S_p}$$

und es gilt nun exakt, dass $T \sim t(m + n - 2)$

Die Notation ist wie zuvor. S_p^2 bezeichnet die gepoolte Stichprobenvarianz und ist ein gewichtetes Mittel der Stichprobenvarianzen.

$$S_p^2 = \frac{(m-1)S_1^2 + (n-1)S_2^2}{m+n-2}$$

Das Auswerten des Tests funktioniert wie gehabt. Durch Übergehen auf die Prüfgröße $t = \frac{(\bar{y}-\bar{x})-d_0}{\sqrt{1/m+1/n} s_p}$ und bestimmen der rejection region (für den zweiseitigen Test $1 - \alpha/2$ Quantil der $t(m+n-2)$ Verteilung) kann die Testentscheidung getroffen werden. H_0 verwerfen, falls $t \in R$ und ansonsten beibehalten.

Bem.: Auch hier gilt wieder, dass die Annahme der Normalverteilung von X und Y für hinreichend große Stichproben (als Faustregel sollen n **und** m mind. 50 sein) vernachlässigt werden kann. Denn dann liefert der Zentrale Grenzwertsatz die Normalverteilung von T .

disclaimer: Since there has been some confusion in my groups about the differences between the statistical tests covered in the lecture/exercise and when to use which one, I have taken the liberty of providing a brief list and explanation here. (up to lecture_10) However, I would like to emphasize that this document is by no means exhaustive, but only deals with the subject matter to the extent that it is useful for understanding the course. If there are any uncertainties or queries, I can be contacted at stefan.laszlo@tuwien.ac.at.

In principle, the tests considered so far check the position of a position parameter - in our case the mean value μ . The null hypothesis - assumption about the mean value - is tested against the alternative hypothesis at a certain significance level α . e.g:

$$H_0: \mu = \mu_0$$

$$H_1: \mu \neq \mu_0$$

In this specific case, one would speak of a two-sided test, and the rejection region is formed on both sides. Other variants are one-sided tests, which can be taken from the lecture notes. In many cases, H_1 corresponds to the negation of H_0 , i.e. a partition of the parameter space. However, this does not necessarily have to be the case and depends on the context to be tested. However, the parameter spaces under the two hypotheses are always disjoint from each other.

Now I would like to turn to the essential aspect of this elaboration and explain the basic distinction between one- and two-sample tests.

one-sample test

Given here a sequence of observations $x_1, \dots, x_n$, the sample, which corresponds to a realization of iid. random variables $X_1, \dots, X_n$. These random variables are assumed to have a certain distribution with mean value μ_0 . The aim of the statistical test is now to validate or reject this assumption about the expected value of the population using the empirical mean value $\bar{x}$.

one-sample z-test

Now let the sequence of iid. random variables $X_1, \dots, X_n$, for which $X \sim N(\mu_x, \sigma_x^2)$ applies. The decisive factor is that in this case the standard deviation is assumed to be **known** and under the null hypothesis $\mu_x = \mu_0$, the test statistic $Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$ is therefore normally distributed. Now move on to the test variable $z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$ and use the standard normal distribution to make the test decision. H_0 is rejected if $z \in R$ and otherwise retained.

note: The assumption that X is necessarily normally distributed can be neglected for sufficiently large samples (as a rule of thumb, n should be at least 30), because the central limit theorem still gives us that $Z \sim_{H_0} N(0, 1)$.

one-sample t-test

The initial situation is almost the same. Again, normally distributed iid. random variables are given, but now with the difference that the standard deviation is **unknown**. Obviously, it is estimated by the empirical standard deviation of the sample, which under the null hypothesis $\mu_x = \mu_0$ leads to the test statistic $T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$ not being normally distributed, but t-distributed, with $n - 1$ degrees of freedom. The evaluation of the test is completely analogous. Once again, we switch to the test variable $t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$ and determine the rejection region using the $t(n-1)$ distribution. H_0 is rejected if $t \in R$ and otherwise retained.

note: The assumption that X is necessarily normally distributed can be neglected for sufficiently large samples (as a rule of thumb, n should be at least 30), because the central limit theorem then gives us that

$T \sim_{H_0} N(0, 1)$. To determine R , it is therefore sufficient to fall back on the standard normal distribution for large n .

two-sample t-test

Given here are **two** independent (**the dependent case is not part of the lecture material**) sequences of observations $x_1, \dots, x_n$ and $y_1, \dots, y_m$, the samples, each of which corresponds to a realization of iid. random variables $X_1, \dots, X_n$ with $X \sim N(\mu_1, \sigma_1^2)$ and $Y_1, \dots, Y_m$ with $Y \sim N(\mu_2, \sigma_2^2)$ respectively. The variances σ_1^2 and σ_2^2 are **unknown**. (otherwise we would be in the setting of the two-sample z-test) In the context of the null hypothesis, an assumption is made about the position of the mean values μ_1 and μ_2 . For example, here is the case of the two-sided test:

$$H_0: \mu_1 - \mu_2 = d_0$$

$$H_1: \mu_1 - \mu_2 \neq d_0$$

Very often we set $d_0 = 0$ - to check the equality of μ_1 and μ_2 . In any case, the aim of the statistical test is to validate or reject this assumption about the expected values of the populations at a certain significance level α using the empirical mean values $\bar{x}$ and $\bar{y}$. The type of specific test now depends on whether the variances σ_1^2 and σ_2^2 are equal or not. We make a distinction:

Welch test

In this case, the variances σ_1^2 and σ_2^2 are assumed to be **unequal**. The test statistic has the following form under the null hypothesis:

$$T = \frac{(\bar{Y} - \bar{X}) - d_0}{\sqrt{\frac{S_1^2}{n} + \frac{S_2^2}{m}}}$$

and it is approximately true that $T \sim t(\nu)$ with

$$\nu = \frac{\left(\frac{s_1^2}{n} + \frac{s_2^2}{m}\right)^2}{\frac{1}{n-1} \left(\frac{s_1^2}{n}\right)^2 + \frac{1}{m-1} \left(\frac{s_2^2}{m}\right)^2}$$

In the above illustration, S_1 denotes the empirical standard deviation of σ_1 and analogously for S_2 . Furthermore, s_1 is the evaluation of S_1 based on the sample $x_1, \dots, x_n$ and again analogous for s_2 . Evaluating the test works as before. The test decision can be made by switching to the test variable $t = \frac{(\bar{y} - \bar{x}) - d_0}{\sqrt{s_1^2/n + s_2^2/m}}$ and determining the rejection region (for the two-sided test $1 - \alpha/2$ quantile of the $t(\nu)$ distribution). H_0 can be rejected if $t \in R$ and retained otherwise.

note: The assumption that X and Y are necessarily normally distributed can be neglected for sufficiently large samples (as a rule of thumb, n **and** m should be at least 50), because the central limit theorem then gives us that $T \sim_{H_0} N(0, 1)$. To determine R , it is therefore sufficient to fall back on the standard normal distribution for large n and m .

Student t-test

In this case, the variances σ_1^2 and σ_2^2 are assumed to be **equal**. The test statistic has the following form under the null hypothesis:

$$T = \frac{(\bar{Y} - \bar{X}) - d_0}{\sqrt{\frac{1}{m} + \frac{1}{n}} S_p}$$

and it now applies exactly that $T \sim t(m + n - 2)$

The notation is as before. S_p^2 denotes the pooled sample variance and is a weighted mean of the sample variances.

$$S_p^2 = \frac{(m-1)S_1^2 + (n-1)S_2^2}{m+n-2}$$

The evaluation of the test works as usual. The test decision can be made by passing to the test variable $t = \frac{(\bar{y}-\bar{x})-d_0}{\sqrt{1/m+1/n} s_p}$ and determining the rejection region (for the two-sided test $1 - \alpha/2$ quantile of the $t(m+n-2)$ distribution). H_0 can be rejected if $t \in R$ and retained otherwise.

note: Again, the assumption of the normal distribution of X and Y can be neglected for sufficiently large samples (as a rule of thumb, n **and** m should be at least 50). This is because the central limit theorem then provides the normal distribution of T .