

Statistik_zsmf

Disclaimer

Zur Erstellung dieses Dokuments wurde sehr viel mit LLMs gearbeitet. Die Informationen können fehlerhaft und unvollständig sein, deshalb unbedingt schon mit einer Grundahnung an die Sache herangehen und nicht ausschließlich die Zusammenfassung zum Lernen, sondern viel eher zum schnellen Wiederholen verwenden!

Generell ist die Auffassung des Stoffs hier sehr verkürzt und zielt ausschließlich auf Wiederholung ab!

Inhalt

- [1 - Einführung](#)
- [12 - Kombinatorik und Wahrscheinlichkeitsräume](#)
- [13 - Kombinatorik und Wahrscheinlichkeitsräume \(Fortsetzung\)](#)
- [14 - Stetige Wahrscheinlichkeitsräume & Zufallsvariablen](#)
- [15 - Kovarianz, Korrelation, Gesetz der großen Zahlen & Zentraler Grenzwertsatz](#)
- [16 - Deskriptive Statistik & Grundlagen der Punktschätzung](#)
- [17 - Konfidenzintervalle & Hypothesentests](#)
- [18 - Einführung in die Hypothesentests](#)
- [19 - Hypothesentests & Fehlerarten](#)
- [110 - Proportions](#)
- [111 - Goodness of fit & Independence](#)
- [112 - Simple linear Regression](#)

l1 - Einführung

Wahrscheinlichkeitstheorie vs. Statistik

Beide Disziplinen befassen sich mit Zufallsprozessen, jedoch aus unterschiedlichen Blickwinkeln.

Deterministisch vs. Zufällig (Random)

- **Deterministisch:** Der Ausgang steht fest (Gewissheit). Bsp: Dein Name, das Datum von Ostern, das Ergebnis eines Spiels von gestern.
- **Zufällig:** Es gibt mehrere mögliche Ausgänge (Ungewissheit). Bsp: Name der nächsten Person, die den Raum betritt, Wetter in einem Monat, Ergebnis des morgigen Spiels.

Die methodischen Unterschiede

Merkmal	Wahrscheinlichkeitstheorie	Statistik
Fokus	Grundgesamtheit (Population) ist bekannt.	Stichprobe/Daten sind beobachtet.
Ziel	Berechnung der Wahrscheinlichkeit von Ereignissen.	Rückschluss auf die Grundgesamtheit.
Natur	Logisch, in sich geschlossen, "sauber".	"Dreckiger", eher eine Kunstform (Interpretation).
Ergebnis	Eine exakt richtige Antwort.	Oft keine einzelne "korrekte" Antwort.

☰ Beispiel: Münzwurf

- **Wahrscheinlichkeit:** Eine faire Münze ($p = 0.5$) wird 100x geworfen. Wie hoch ist die Chance auf ≥ 60 mal Kopf? (Prozess ist bekannt, Ereignis wird gesucht).
- **Statistik:** Wir werfen eine unbekannte Münze 100x und zählen 60x Kopf. Ist die Münze fair? (Daten sind bekannt, Prozess/Eigenschaft wird gesucht).

Anwendungen

Die Anwendungsgebiete sind vielfältig: Medizinische Tests, Machine Learning (AI), Glücksspiel, Versicherungen & Investment, Computergrafik (Rendering), Epidemiologie und Marketing. In der Vorlesung nutzen wir oft **Toy Models** (Münzen, Würfel) zur Vereinfachung.

Grundlagen der Wahrscheinlichkeitstheorie

Definition

Intuitiv ist die Wahrscheinlichkeit ein Maß für die Unsicherheit des Eintretens eines Ereignisses. Ein **Ereignis** besteht aus den gewünschten Ausgängen im Verhältnis zu allen möglichen Ausgängen.

Mathematische Definition (Laplace-Prinzip)

Für einen endlichen Stichprobenraum mit gleich wahrscheinlichen Ausgängen gilt:

$$P(A) = \frac{\text{Anzahl der gewünschten Ergebnisse}}{\text{Anzahl aller möglichen Ergebnisse}} = \frac{|A|}{|\Omega|}$$

- $P(A)$ ist die Wahrscheinlichkeit des Ereignisses A .
- $|\Omega|$ (Omega) ist der gesamte **Stichprobenraum** (alle Möglichkeiten).
- $|A|$ ist die Anzahl der günstigen Ausgänge für das Ereignis A .

Beispiel: 3x Münzwurf

Frage: Wie hoch ist die Wahrscheinlichkeit für genau 1x Kopf bei 3 Würfeln?

1. **Stichprobenraum Ω :** Alle 8 Möglichkeiten auflisten.

$$\Omega = \{HHH, HHT, HTH, HTT, THH, THT, TTH, TTT\}$$

2. **Ereignis A :** Alle Ausgänge mit genau 1x "Head".

$$A = \{HTT, THT, TTH\}$$

(Das sind 3 Ausgänge)

3. **Berechnung:**

$$P(A) = \frac{|A|}{|\Omega|} = \frac{3}{8} = 37.5\%$$

Das Prinzip

Angenommen, es gibt n mögliche Ausgänge, die alle gleich wahrscheinlich sind. Für k gewünschte Ausgänge beträgt die Wahrscheinlichkeit eines gewünschten Ausgangs k/n .

l2 - Kombinatorik und Wahrscheinlichkeitsräume

1. Mengenlehre (Sets)


Eine Menge ist eine Sammlung von unterschiedlichen Elementen. Man kann sie sich wie "Beutel mit Elementen" vorstellen.

Grundbegriffe & Operationen

Gegeben seien Mengen A und B in einem Universum Ω :

- **Element:** $x \in A$ (x ist in A enthalten).
- **Teilmenge:** $A \subseteq B$ (jedes Element von A ist auch in B).
- **Leere Menge:** $\emptyset$ (enthält keine Elemente).
- **Durchschnitt:** $A \cap B = \{x : x \in A \text{ und } x \in B\}$.
- **Vereinigung:** $A \cup B = \{x : x \in A \text{ oder } x \in B\}$.
- **Differenz:** $A \setminus B$ (Elemente in A , die nicht in B sind).
- **Symmetrische Differenz:** $A \triangle B = (A \setminus B) \cup (B \setminus A)$ (Elemente, die in genau einer der beiden Mengen sind).
- **Komplement:** $A^c = \Omega \setminus A$ (alle Elemente des Universums, die nicht zu A gehören).
- **Größe/Kardinalität:** $|A|$ (Anzahl der Elemente in A).

Visualisierung (Venn-Diagramme)



Rechenregeln für Mengen

- **Kommutativität:** $A \cap B = B \cap A \mid A \cup B = B \cup A$
- **Assoziativität:** $(A \cap B) \cap C = A \cap (B \cap C)$
- **Distributivität:** $(A \cup B) \cap C = (A \cap C) \cup (B \cap C)$
- **De Morgan's Laws:** $(A \cap B)^c = A^c \cup B^c \mid (A \cup B)^c = A^c \cap B^c$

Kartesisches Produkt

Das Produkt $A \times B$ enthält alle geordneten Paare (a, b) :

$$A \times B = \{(a, b) : a \in A \text{ and } b \in B\}$$

$$A \times B = \{(1, 2), (1, 3), (1, 4), (1, 5), (2, 2), (2, 3), (2, 4), (2, 5), (3, 2), (3, 3), (3, 4), (3, 5)\}$$

which is better displayed via a table


$A \times B$		B			
		2	3	4	5
A	1	(1, 2)	(1, 3)	(1, 4)	(1, 5)
	2	(2, 2)	(2, 3)	(2, 4)	(2, 5)
	3	(3, 2)	(3, 3)	(3, 4)	(3, 5)

2. Inklusions-Exklusions-Prinzip

Wird verwendet, um die Größe der Vereinigung von Mengen zu berechnen, ohne Elemente doppelt zu zählen.

Für zwei Mengen:

$$|A \cup B| = |A| + |B| - |A \cap B|$$



Für drei Mengen:

$$|A \cup B \cup C| = |A| + |B| + |C| - |A \cap B| - |A \cap C| - |B \cap C| + |A \cap B \cap C|$$

≡ Beispiel: Band-Mitglieder

7 Sänger (S), 4 Gitarristen (G), 2 Personen machen beides ($S \cap G$).

Größe der Band: $|S \cup G| = 7 + 4 - 2 = 9$.

3. Kombinatorik: Zählmethoden

Mathematische Werkzeuge

- **Fakultät:** $n! = n(n-1)(n-2) \cdots 1$ (Anzahl der Anordnungen von n Objekten). Definition: $0! = 1$.

- **Binomialkoeffizient:** "n über k" ($\binom{n}{k}$). Anzahl der Möglichkeiten, k Elemente aus n ohne Reihenfolge zu wählen.

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}$$

- **Produktregel:** Wenn Aktion 1 auf n Arten und Aktion 2 auf m Arten möglich ist, gibt es insgesamt $n \cdot m$ Kombinationen.

Die 4 Grundfälle der Kombinatorik

Typ	Geordnet (Reihenfolge zählt)	Ungeordnet (Reihenfolge egal)
Ohne Wiederholung	Variation: $\frac{n!}{(n-k)!}$	Kombination: $\binom{n}{k}$
Mit Wiederholung	Variation: n^k	Kombination: $\binom{n-1+k}{k}$

Permutationen (Anordnungen)

- **Ohne Wiederholung:** $n!$ Möglichkeiten, n unterschiedliche Objekte anzuordnen (z.B. 52 Spielkarten: $52!$).
- **Mit Wiederholung:** Wenn einige Objekte identisch sind (z.B. Kartensymbole).

$$\frac{n!}{n_1!n_2! \cdots n_k!}$$

(Man teilt durch die Fakultäten der Gruppengrößen, um "Überzählen" zu verhindern).

Variationen (Auswahl k aus n , Reihenfolge wichtig)

- **Ohne Wiederholung:** k unterschiedliche Elemente wählen (z.B. Gold, Silber, Bronze bei 8 Läufern: $8 \cdot 7 \cdot 6 = 336$).
- **Mit Wiederholung:** Elemente dürfen mehrfach gewählt werden (z.B. 64-Bit Zahl: 2^{64}).

Kombinationen (Auswahl k aus n , Reihenfolge egal)

- **Ohne Wiederholung:** Eine Teilmenge wählen (z.B. Poker-Hand mit 5 Karten aus 52: $\binom{52}{5}$).
- **Mit Wiederholung:** "Bars and Stripes" Modell.

Stell dir vor, du hast k Objekte und $n - 1$ Trennwände. Die Gesamtzahl der Positionen ist $n - 1 + k$, daraus wählt man k Plätze für die Objekte: $\binom{n-1+k}{k}$.

4. Wahrscheinlichkeitsräume

Ein Wahrscheinlichkeitsraum ist ein Tripel $(\Omega, \mathfrak{F}, P)$.

- **Stichprobenraum (Ω):** Menge aller möglichen Ergebnisse (Elementarereignisse ω).
- **σ -Algebra ($\mathfrak{F}$):** Menge aller betrachteten Ereignisse (bei endlichen Mengen meist die Potenzmenge 2^Ω).

- **Wahrscheinlichkeitsmaß (P):** Eine Funktion $P : \mathfrak{F} \rightarrow [0, 1]$, die jedem Ereignis eine Zahl zuordnet.

☰ Beispiel: D&D Goblin Kampf

Ein Goblin hat 4 HP. Schaden durch W6 Wurf:

- $\Omega: \{\text{Goblin ok, Goblin bewusstlos, Goblin tot}\}$
- $P(\text{Goblin ok}) = P(\{1, 2\}) = 2/6 = 1/3$
- $P(\text{Goblin bewusstlos}) = P(\{3\}) = 1/6$
- $P(\text{Goblin tot}) = P(\{4, 5, 6\}) = 3/6 = 1/2$

Die Wahrscheinlichkeit, dass der Goblin noch lebt, ist die Summe der ersten beiden:

$$1/3 + 1/6 = 1/2.$$

l3 - Kombinatorik und Wahrscheinlichkeitsräume (Fortsetzung)

1. Grundlagen des Wahrscheinlichkeitsraums

Ein Wahrscheinlichkeitsraum $(\Omega, \mathfrak{G}, P)$ besteht aus drei Komponenten:

Zufallsexperiment & Stichprobenraum

- **Zufallsexperiment:** Ein wiederholbares Verfahren mit wohldefinierten möglichen Ergebnissen.
- **Stichprobenraum (Ω) :** Die Menge aller möglichen Ergebnisse. Die Elemente $\omega \in \Omega$ werden **Elementarereignisse** genannt.
- **Ereignisse:** Teilmengen des Stichprobenraums $(A \subseteq \Omega)$.
 - $\emptyset$: Unmögliches Ereignis.
 - Ω : Sicheres Ereignis.
 - A^c : Gegenereignis (Komplement) zu A .

Ereignisalgebra (σ -Algebra)

- Die Menge aller Ereignisse $\mathfrak{G} \subseteq 2^\Omega$ ist eine **σ -Algebra**.
- Sie enthält $\Omega \in \mathfrak{G}$ und ist abgeschlossen unter Komplementbildung, abzählbaren Vereinigungen und Schnitten.
- Bei endlichen Mengen ist $\mathfrak{G}$ oft die Potenzmenge ($|\mathfrak{G}| = 2^{|\Omega|}$).

Wahrscheinlichkeitsmaß (P)

- Eine Funktion $P : \mathfrak{G} \rightarrow [0, 1]$, die Ereignissen Wahrscheinlichkeiten zuweist.
- **Axiome (Kolmogorov):**
 1. **Nicht-Negativität:** $P(A) \geq 0$ für alle $A \in \mathfrak{G}$.
 2. **Normiertheit:** $P(\Omega) = 1$.
 3. **σ -Additivität:** Für eine Folge paarweise disjunkter Ereignisse A_i gilt:

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

2. Diskrete Wahrscheinlichkeitsräume

Ein Wahrscheinlichkeitsraum heißt diskret, wenn der Stichprobenraum $\Omega = \{\omega_1, \omega_2, \dots\}$ **abzählbar** ist.

- Die Wahrscheinlichkeitsfunktion P ist eindeutig durch die Wahrscheinlichkeiten der Elementarereignisse definiert.
- Es muss gelten: $0 \leq p_i \leq 1$ und $\sum_i p_i = 1$, wobei $p_i = P(\{\omega_i\})$.
- Wahrscheinlichkeit eines Ereignisses A : $P(A) = \sum_{\omega_i \in A} p_i$.

Probability tables provide mappings;

The probability of an event $A \subseteq \Omega$ is

events ω_1	ω_1	ω_2	$\dots$	ω_i	$\dots$
probability p_i	p_1	p_2	$\dots$	p_i	$\dots$

$$P(A) = \sum_{\omega \in A} P(\{\omega\}) = \sum_{\omega_i \in A} p_i$$

where

$$0 \leq p_i \leq 1 \text{ and } \sum_i p_i = 1$$

Beispiele für diskrete Räume

- **Zweifacher Münzwurf:** $\Omega = \{HH, HT, TH, TT\}$. $|\mathfrak{S}| = 2^4 = 16$.

We toss a *fair coin* twice.

RANDOM EXPERIMENT: toss the fair coin twice and **list the outcome**.

SAMPLE SPACE: $\Omega = \{HH, HT, TH, TT\} = \{\omega_1, \omega_2, \omega_3, \omega_4\}$.

σ -ALGEBRA: Is the power set (set of all subsets) of size $|\mathfrak{S}| = 2^{|\Omega|} = 2^4 = 16$

$$\mathfrak{S} = 2^\Omega = \{\emptyset, \{HH\}, \{HT\}, \{TH\}, \{TT\}, \{HH, HT\}, \{HH, TH\}, \{HH, TT\}, \{HT, TH\}, \{HT, TT\}, \{TH, TT\}, \{HH, HT, TH\}, \{HH, HT, TT\}, \{HH, TH, TT\}, \{HT, TH, TT\}, \Omega\}$$

PROBABILITY: All the outcomes are equally likely (fair coin)

ω	HH	HT	TH	TT
$P(\omega)$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{4}$

EVENTS: Examples

One head in two tosses

$$A = \{HT, TH\}$$

$$P(A) = P(\{HT\}) + P(\{TH\}) = \frac{1}{2}$$

At least one head

$$B = \{HH, HT, TH\} = \Omega \setminus \{TT\}$$

$$P(B) = 1 - P(\{TT\}) = 1 - \frac{1}{4} = \frac{3}{4}$$

At least *three* heads

$$C = \emptyset$$

$$P(C) = 0$$

≡ Summe zweier 6-seitiger Würfel (Modellwahl)

1. **Version 1 (Tupel):** $\Omega = \{(1, 1), \dots, (6, 6)\}$, alle 36 outcomes gleichwahrscheinlich ($1/36$).

2. **Version 2 (Summen):** $\Omega = \{2, 3, \dots, 12\}$. Hier sind Outcomes **nicht** gleichwahrscheinlich.

$$P(\{\omega\}) = \frac{\min(\omega-1, 13-\omega)}{36}.$$

- **Unendlicher Münzwurf (bis zum ersten Kopf):** Abzählbar unendlich.

$$\Omega = \{H, TH, TTH, \dots\}. P(\text{Kopf im } i\text{-ten Wurf}) = \frac{1}{2^i}.$$

- **Poisson-Verteilung (z.B. Taxis pro Stunde):** $\Omega = \mathbb{N}_0$.

$$p_k = P(\{k\}) = e^{-\lambda} \frac{\lambda^k}{k!} \text{ (wobei } \lambda \text{ die Durchschnittsrate ist).}$$

3. Stetige Wahrscheinlichkeitsräume

Wird verwendet, wenn Ergebnisse ein Kontinuum bilden (z.B. Lebensdauer einer Glühbirne).

- **Stichprobenraum:** $\Omega = [0, \infty) \subset \mathbb{R}$ (alle nicht-negativen reellen Zahlen).
- Statt Summen nutzt man hier die **Wahrscheinlichkeitsdichtefunktion (p.d.f.)** und **Integration**.

4. Rechenregeln der Wahrscheinlichkeit

Wichtige Folgerungen aus den Axiomen

- **Unmögliches Ereignis:** $P(\emptyset) = 0$.
- **Komplement:** $P(A^c) = 1 - P(A)$.
- **Monotonie:** Wenn $A \subseteq B$, dann gilt $P(A) \leq P(B)$.
- **Inklusion-Exklusion:** $P(A \cup B) = P(A) + P(B) - P(A \cap B)$.
- **Spezialfall Disjunktheit:** Wenn $A \cap B = \emptyset$, dann $P(A \cup B) = P(A) + P(B)$ und $P(A \cap B) = 0$ (gegenseitiger Ausschluss).

COMPLEMENT: $P(A^c) = 1 - P(A)$

$$1 \stackrel{2}{=} P(\Omega) = P(A \cup A^c) \stackrel{3}{=} P(A) + P(A^c)$$

INCLUSION-EXCLUSION PRINCIPLE: $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

$$P(A \cup B) \stackrel{3}{=} P(A \setminus (A \cap B)) + P(B) \quad (1)$$

$$P(A) \stackrel{3}{=} P(A \setminus (A \cap B)) + P(A \cap B) \quad (2)$$

$$P(A \cup B) - P(A) = P(B) - P(A \cap B) \quad (1 - 2)$$

MONOTONICITY: $A \subseteq B$ implies $P(A) \leq P(B)$

$$P(A) \stackrel{1}{\leq} P(A) + P(B \setminus A) \stackrel{3}{=} P(B)$$

to list a few, Venn diagrams are useful for understanding

5. Bedingte Wahrscheinlichkeit & Unabhängigkeit

Bedingte Wahrscheinlichkeit

Gibt an, wie sich die Wahrscheinlichkeit eines Ereignisses A ändert, wenn man Zusatzinformationen über ein Ereignis B hat ($P(B) > 0$ vorausgesetzt).

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

- Wenn $B = \Omega$ (keine echte Zusatzinfo), dann $P(A|\Omega) = P(A)$.
- Wenn $A \cap B = \emptyset$ (disjunkt), dann $P(A|B) = 0$.
- Wenn $A \supseteq B$ (B ist Teilmenge von A), dann $P(A|B) = 1$.

Unabhängigkeit

Zwei Ereignisse A, B sind unabhängig ($A \perp B$), wenn gilt:

$$P(A \cap B) = P(A) \cdot P(B)$$

- Das bedeutet auch: $P(A|B) = P(A)$. Das Eintreten von B beeinflusst die Wahrscheinlichkeit von A nicht.

🔗 Unabhängigkeit bei mehreren Ereignissen

Drei Ereignisse A, B, C sind unabhängig, wenn sie:

1. **Paarweise unabhängig** sind ($P(A \cap B) = P(A)P(B)$, etc.).
2. **Gemeinsam unabhängig** sind: $P(A \cap B \cap C) = P(A)P(B)P(C)$.

(Hinweis: Nur paarweise Unabhängigkeit reicht nicht für die Unabhängigkeit der gesamten Gruppe aus!)

6. Totale Wahrscheinlichkeit & Satz von Bayes

Gesetz der totalen Wahrscheinlichkeit

Wenn man den Stichprobenraum Ω in disjunkte Teilereignisse B_i zerlegt (Partition), kann man $P(A)$ berechnen durch:


$$P(A) = \sum_{i=1}^{\infty} P(A|B_i)P(B_i)$$

If *only the conditional probabilities and the probabilities of the conditional event are known*, the **total probability** of A results from

$$P(A) = P(A | B)P(B) + P(A | B^c)P(B^c).$$

Given a **partition of the sample space** Ω that is a sequence $B_1, B_2, B_3, \dots$ of pair-wise disjoint events $B_i \cap B_j = \emptyset$ for all $i \neq j$ and $\bigcup_{i=1}^{\infty} B_i = \Omega$, then

$$P(A) = \sum_{i=1}^{\infty} P(A \cap B_i) = \sum_{i=1}^{\infty} P(A | B_i)P(B_i)$$



Satz von Bayes

Erlaubt das "Umdrehen" der Bedingung. Sehr wichtig für statistische Schätzungen (Prior zu Posterior).

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

- **Alternative Form (mit totaler Wahrscheinlichkeit):**

$$P(H_i|B) = \frac{P(B|H_i)P(H_i)}{\sum_j P(B|H_j)P(H_j)}$$

- $P(H_i)$: **Prior**-Wahrscheinlichkeit (Wissen vor der Beobachtung).
- $P(H_i|B)$: **Posterior**-Wahrscheinlichkeit (aktualisiertes Wissen nach Beobachtung von B).

☰ Urnen-Beispiel (Marbles)

Urne mit 5 roten (R) und 2 blauen (B) Murmeln. Eine Murmel wird gezogen, durch die andere Farbe ersetzt, dann wird eine zweite Murmel gezogen.

1. $P(R_2)$ berechnen via totaler Wahrscheinlichkeit über R_1 und B_1 .
2. $P(R_1|R_2)$ berechnen via Bayes.

Example: Red and Blue Marbles


A urn contains 5 red and 2 blue marbles.

We draw a random marble and replace it with a marble of the other color, then a second marble is drawn.

1. What is the probability that the *second marble is red*?
2. What is the probability the *first marble was red given the second marble is red*?

We use a *probability tree* to solve this problem;

Let R_i and B_i be the event of a red or blue marble on the i 'th draw.



Let R_i and B_i be the event of a red or blue marble on the i 'th draw.


1. Using the *Law of Total Probability*

$$\begin{aligned} P(R_2) &= P(R_2 | R_1)P(R_1) + P(R_2 | B_1)P(B_1) \\ &= \frac{4}{7} \cdot \frac{5}{7} + \frac{6}{7} \cdot \frac{2}{7} = \frac{32}{49} \end{aligned}$$

noting that $R_1 \cup B_1 = \Omega$.

2. Using *Bayes Theorem* we get

$$\begin{aligned} P(R_1 | R_2) &= \frac{P(R_2 | R_1)P(R_1)}{P(R_2)} \\ &= \frac{(4/7) \cdot (5/7)}{32/49} = \frac{5}{8} \end{aligned}$$



I4 - Stetige Wahrscheinlichkeitsräume & Zufallsvariablen

1. Stetiger Wahrscheinlichkeitsraum $(\Omega, \mathcal{S}, P)$

Ein stetiger Wahrscheinlichkeitsraum ist gegeben, wenn die Ergebnismenge Ω **nicht abzählbar** ist.

- **Klassisches Setting:** $\Omega \subseteq \mathbb{R}$ ist ein Intervall oder eine Vereinigung von Intervallen.
 - **Beispiele:** $\Omega = \mathbb{R}$, $\Omega = [0, 1]$, $\Omega = [0, \infty)$, $\Omega = (-\infty, -1] \cup [1, \infty)$.
- **Borel σ -Algebra:** Die kleinste σ -Algebra $\mathcal{S}$, die alle offenen Intervalle in $\mathbb{R}$ enthält.
- **Problem:** Elementarereignisse können nicht mehr einfach in einer Tabelle aufgelistet werden. Daher ist ein praktischer Ansatz über **Zufallsvariablen** nötig.

2. Zufallsvariablen (Random Variables)

Eine Zufallsvariable X ist eine reellwertige Funktion von Elementarereignissen.

- **Definition:** $X : \Omega \rightarrow \mathbb{R}$, wobei jedem $\omega \in \Omega$ eine reelle Zahl $X(\omega) = x \in \mathbb{R}$ zugeordnet wird.
 - x nennt man eine **Realisation** von X .
- **Bildraum (Image/Feature Space):** Die Menge $\{X(\omega) : \omega \in \Omega\}$ aller möglichen Werte von X .
- **Ereignisse:** Werden durch Urbilder definiert: $X^{-1}(\mathcal{X}) = \{\omega \in \Omega : X(\omega) \in \mathcal{X}\}$ für $\mathcal{X} \subseteq \mathbb{R}$.
- **Notation:** In der Praxis nutzt man beschreibende Notationen:
 - $[X = x] = X^{-1}(\{x\})$
 - $[X < 0] = X^{-1}((-\infty, 0))$
 - $[|X| \leq 1] = X^{-1}([-1, 1])$

Diskrete vs. Stetige Zufallsvariablen

Typ	Definition	Beispiel
Diskret	Bild von X ist endlich oder abzählbar.	Anzahl der Kinder, die nächsten Dienstag geboren werden.
Stetig	Bild von X ist überabzählbar (z. B. Intervalle).	Zeitpunkt, zu dem das erste Kind nächsten Dienstag geboren wird.

 **Mischformen (Mixtures) werden hier ignoriert.**

3. Wahrscheinlichkeitsmaße und Verteilungen

A. Diskrete Zufallsvariablen: Wahrscheinlichkeitsfunktion (pmf)

Die **Probability Mass Function (pmf)** f ordnet jedem Wert die Wahrscheinlichkeit seines Auftretens zu.

- **Eigenschaften:**

- $f(x) = P(X = x)$
- $0 \leq f(x) \leq 1$ für alle x
- $\sum f(x) = 1$ (Summe über alle möglichen Werte)
- Wenn X den Wert x nie annimmt, ist $f(x) = 0$.

		Probability Table					
values	x	1	2	3	4	5	6
pmf	$f(x)$	$\frac{1}{36}$	$\frac{3}{36}$	$\frac{5}{36}$	$\frac{7}{36}$	$\frac{9}{36}$	$\frac{11}{36}$

$$\sum_{x=1}^6 f(x) = 1$$


B. Stetige Zufallsvariablen: Wahrscheinlichkeitsdichte (pdf)

Eine Zufallsvariable ist stetig, wenn eine Funktion $f: \mathbb{R} \rightarrow [0, \infty)$ existiert, sodass:

$$P(a \leq X \leq b) = \int_a^b f(x) dx$$

- **Eigenschaften der Dichte f :**

- $f(x) \geq 0$ (nicht-negativ).
- Die Dichte selbst ist **keine** Wahrscheinlichkeit; Werte können > 1 sein!
- Das Integral über den gesamten Raum ist 1: $\int_{-\infty}^{\infty} f(x) dx = 1$.
- Die Wahrscheinlichkeit für einen exakten Punkt ist **immer Null**:
 $P(X = a) = \int_a^a f(x) dx = 0$.
- Daraus folgt: $P(a \leq X \leq b) = P(a < X \leq b) = P(a \leq X < b) = P(a < X < b)$.



C. Verteilungsfunktion (CDF)

Die **Cumulative Distribution Function (cdf)** F identifiziert eine Zufallsvariable (egal ob diskret oder stetig) eindeutig:

$$F(x) = P(X \leq x)$$


- **Eigenschaften:**

- $0 \leq F(x) \leq 1$.
- Monoton steigend: $x \leq y \Rightarrow F(x) \leq F(y)$.

- Rechtsseitig stetig: $\lim_{h \rightarrow 0+} F(x+h) = F(x)$.
- Asymptotik: $\lim_{x \rightarrow -\infty} F(x) = 0$ und $\lim_{x \rightarrow \infty} F(x) = 1$.

❗ Unterschied im CDF-Verlauf:

- Bei diskreten RVs ist die CDF eine **Treppenfunktion**.
- Bei stetigen RVs ist die CDF **stetig**.



Zusammenhang CDF, pmf und pdf:

- **Diskret:** $F(x) = \sum_{x_i \leq x} f(x_i)$.
- **Stetig:** $F(x) = \int_{-\infty}^x f(z) dz$.
- **Wichtig:** Bei stetigen RVs ist die Dichte die Ableitung der CDF: $f(x) = F'(x)$.
- Für beide gilt: $P(a < X \leq b) = F(b) - F(a)$.

4. Momente: Erwartungswert und Varianz

Erwartungswert $\mathbb{E}[X]$

Der Erwartungswert ist das gewichtete Mittel der möglichen Ausgänge (1. rohes Moment).

- **Diskret:** $\mathbb{E}[X] = \sum_{i=1}^{\infty} x_i f(x_i)$.
- **Stetig:** $\mathbb{E}[X] = \int_{-\infty}^{\infty} x f(x) dx$.

⚠ **Absolute Konvergenz wird vorausgesetzt, ansonsten existiert der Erwartungswert nicht oder ist $\pm\infty$.**

Eigenschaften des Erwartungswerts:

- **Linearität:** $\mathbb{E}[aX + b] = a\mathbb{E}[X] + b$ und $\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y]$.

- Bei Unabhängigkeit: $\mathbb{E}[X \cdot Y] = \mathbb{E}[X] \cdot \mathbb{E}[Y]$.
- **Transformationsformel:** $\mathbb{E}[g(X)] = \int_{-\infty}^{\infty} g(x)f(x)dx$ (bzw. Summe bei diskreten RVs).

Varianz $\mathbb{V}ar(X)$

Ein Maß für die Streuung (Dispersion).

$$\mathbb{V}ar(X) = \mathbb{E}[(X - \mathbb{E}X)^2] = \mathbb{E}[X^2] - (\mathbb{E}X)^2$$

- **Standardabweichung:** $\sigma = \sqrt{\mathbb{V}ar(X)}$.
- **Eigenschaften:**
 - $\mathbb{V}ar(aX + b) = a^2 \mathbb{V}ar(X)$.
 - Wenn X, Y unabhängig: $\mathbb{V}ar(X + Y) = \mathbb{V}ar(X) + \mathbb{V}ar(Y)$.
 - Allgemein (mit Kovarianz): $\mathbb{V}ar(X + Y) = \mathbb{V}ar(X) + \mathbb{V}ar(Y) + 2\mathbb{C}ov(X, Y)$.

Kovarianz:



$\mathbb{C}ov(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)]$. Sie misst die gemeinsame Variabilität.

5. Quantile und Perzentile

Da die CDF nicht immer 1-zu-1 umkehrbar ist, nutzt man die **generalisierte Inverse** (Quantilsfunktion):

$$F^{-1}(p) = \inf\{x : F(x) \geq p\} \text{ für } p \in (0, 1)$$

- **p -Quantil:** Der Wert x_p , für den gilt $F(x_p) = p$.
- **Besondere Quantile:**
 - **Unteres Quartil:** 25%-Quantil ($p = 0,25$).
 - **Median:** 50%-Quantil ($p = 0,5$) $\rightarrow$ teilt das Bild in zwei gleich wahrscheinliche Teile.
 - **Oberes Quartil:** 75%-Quantil ($p = 0,75$).
- **Perzentile:** Quantile in Schritten von $1/100$ (z. B. 0.1-Quantil = 10-Perzentil).

DISCRETE p -quantile $x_p = F^{-1}(p)$ for $p \in (0, 1)$ CONTINUOUS p -quantile $x_p = F^{-1}(p)$ for $p \in (0, 1)$ 

Stell dir vor, 100 Studenten schreiben eine Klausur. Die Punkte werden sortiert:

- Das **0,25-Quantil** ist die Punktzahl, die der 25. Student (von unten gezählt) hat.
- Wenn dieses Quantil bei **40 Punkten** liegt, weißt du: 25 % der Leute haben 40 oder weniger Punkte erreicht.
- Gleichzeitig haben die restlichen 75 % mehr als (oder genau) 40 Punkte.

6. Transformation stetiger Zufallsvariablen

Wenn X eine Dichte f_X hat, wie lautet die Dichte f_Y von $Y = g(X)$?

Dichtetransformationssatz:

Falls g eine 1-zu-1 Abbildung mit differenzierbarer Inversen g^{-1} ist:

$$f_Y(y) = f_X(g^{-1}(y)) \cdot \left| \frac{d}{dy} g^{-1}(y) \right|$$

7. Wichtige Verteilungen

A. Diskrete Verteilungen

1. **Bernoulli-Verteilung** $X \sim \text{Bernoulli}(p)$:

- Zwei Ausgänge (Erfolg 1, Misserfolg 0).
- $\mathbb{E}[X] = p, \text{Var}(X) = p(1 - p)$.

2. **Binomialverteilung** $X \sim \text{Bin}(n, p)$:

- Anzahl der Erfolge in n unabhängigen Bernoulli-Versuchen.
- $f(x) = \binom{n}{x} p^x (1 - p)^{n-x}$.
- $\mathbb{E}[X] = np, \text{Var}(X) = np(1 - p)$.

3. **Geometrische Verteilung** $X \sim \text{Geom}(p)$:

- Anzahl der Versuche **vor** dem ersten Erfolg.
- $f(x) = (1 - p)^x p$.
- $\mathbb{E}[X] = \frac{1-p}{p}, \mathbb{V}ar(X) = \frac{1-p}{p^2}$.

4. **Poisson-Verteilung** $X \sim \text{Poisson}(\lambda)$:

- Anzahl der Ereignisse in einem Zeitintervall.
- $f(x) = e^{-\lambda} \frac{\lambda^x}{x!}$.
- $\mathbb{E}[X] = \lambda, \mathbb{V}ar(X) = \lambda$.

B. Stetige Verteilungen

1. **Gleichverteilung (Uniform)** $X \sim U(a, b)$:

- Dichte: $f(x) = \frac{1}{b-a}$ für $a < x < b$.
- $\mathbb{E}[X] = \frac{a+b}{2}, \mathbb{V}ar(X) = \frac{(b-a)^2}{12}$.

2. **Exponentialverteilung** $X \sim \text{Exp}(\lambda)$:

- Modelliert Wartezeiten (stetiges Analogon zur geometrischen Verteilung).
- Dichte: $f(x) = \lambda e^{-\lambda x}$ für $x \geq 0$.
- $\mathbb{E}[X] = \frac{1}{\lambda}, \mathbb{V}ar(X) = \frac{1}{\lambda^2}$.

3. **Normalverteilung (Gauß)** $X \sim \mathcal{N}(\mu, \sigma^2)$:

- Dichte: $f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$.
- **Standardnormalverteilung:** $\mu = 0, \sigma^2 = 1$. Notation der CDF: $\Phi(x)$.
- **Standardisierung:** $Z = \frac{X-\mu}{\sigma} \sim \mathcal{N}(0, 1)$.
- **Symmetrie:** $\Phi(-z) = 1 - \Phi(z)$ und $z_p = -z_{1-p}$.

4. **χ^2 -Verteilung** χ_n^2 :

- Summe von n quadratischen, unabhängigen Standardnormalverteilungen.

5. **Student's t-Verteilung** t_n :

- Verhältnis einer Standardnormalverteilung zur Wurzel einer χ^2 -Verteilung. Wichtig für Statistik.

ⓘ Weitere erwähnte Distributionen: > Hypergeometrisch, Wishart, negative Binomial, Log-Normal, Cauchy, Gamma, Beta, F-Verteilung.

I5 - Kovarianz, Korrelation, Gesetz der großen Zahlen & Zentraler Grenzwertsatz

1. Kovarianz (Covariance)

Die Kovarianz ist ein Maß für die **gemeinsame Variabilität** zweier reeller Zufallsvariablen X und Y .

Definition

Die Kovarianz von X und Y ist definiert als:

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)]$$

Die Varianz ist dabei ein Spezialfall der Kovarianz: $\text{Var}(X) = \text{Cov}(X, X)$.

Eigenschaften der Kovarianz

Für Zufallsvariablen X, Y, Z und Konstanten $a, b \in \mathbb{R}$ gilt:

- **Berechnungsformel:** $\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$
- **Symmetrie:** $\text{Cov}(X, Y) = \text{Cov}(Y, X)$
- **Linearität:** $\text{Cov}(aX + b, Y) = a\text{Cov}(X, Y)$
- **Additivität:** $\text{Cov}(X + Y, Z) = \text{Cov}(X, Z) + \text{Cov}(Y, Z)$
- **Varianz einer Summe:** $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$
- **Skalierung der Varianz:** $\text{Var}(aX) = a^2\text{Var}(X)$

Hinweis zu R

In R werden die Funktionen `cov` und `var` verwendet. Es handelt sich um **erwartungstreue Schätzer** mit der Skalierung $n - 1$.

2. Kovarianz und Unabhängigkeit

Die Kovarianz misst die **lineare Abhängigkeit** zwischen Variablen.

- Wenn X und Y **unabhängig** sind, dann gilt $\text{Cov}(X, Y) = 0$.
- **Achtung:** Der Umkehrschluss ist im Allgemeinen **falsch**! Aus einer Kovarianz von 0 folgt nicht zwingend Unabhängigkeit.

Beispiel für $\text{Cov} = 0$ trotz Abhängigkeit

Betrachte $X \sim U(-1, 1)$ und $Y = X^2$. Hier ist Y eine Funktion von X (also maximal abhängig), aber die Kovarianz ist trotzdem 0, da kein **linearer** Zusammenhang besteht.

3. Korrelationskoeffizient (Pearson)

Der Korrelationskoeffizient ist eine "normierte" Kovarianz und dient als Maß für den linearen Zusammenhang.


Definition

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)}\sqrt{\text{Var}(Y)}}$$


Eigenschaften

- **Wertebereich:** $-1 \leq \rho(X, Y) \leq 1$.
- **Standardisierung:** Er entspricht der Kovarianz von standardisierten Variablen (Varianz = 1).
- **Extremwerte:** $\rho(X, Y) = \pm 1$ bedeutet, dass ein perfekter linearer Zusammenhang $Y = aX + b$ besteht. Das Vorzeichen von a entspricht dabei dem Vorzeichen von ρ .


$$\rho(X, Y) = 0$$




$$\rho(X, Y) = 0.5$$



$$\rho(X, Y) = -0.8$$



$$\rho(X, Y) = 1$$



4. Beispiel: Münzwurf (Drei Würfe)

Wir werfen eine faire Münze dreimal.

- X : Anzahl Kopf in den ersten zwei Würfeln.
- Y : Anzahl Kopf in den letzten zwei Würfeln.

with joint probability table

$X \setminus Y$	0	1	2	$P(X = x)$
0	$\frac{1}{8}$	$\frac{1}{8}$	0	$\frac{1}{4}$
1	$\frac{1}{8}$	$\frac{2}{8}$	$\frac{1}{8}$	$\frac{1}{2}$
2	0	$\frac{1}{8}$	$\frac{1}{8}$	$\frac{1}{4}$
$P(Y = y)$	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$	1

Berechnung:

1. Erwartungswerte: $\mathbb{E}X = \mathbb{E}Y = 1$.
2. $\mathbb{E}[XY] = 5/4$.
3. $\text{Cov}(X, Y) = 5/4 - 1 \cdot 1 = 1/4$.
4. $\text{Var}(X) = \text{Var}(Y) = 1/2$.
5. Korrelation: $\rho(X, Y) = \frac{1/4}{1/2} = 1/2$.

🔄 Alternativer Ansatz über Bernoulli-Variablen

Man kann X und Y als Summen von Bernoulli-Variablen B_i (Indikator für Kopf im i -ten Wurf) ausdrücken: $X = B_1 + B_2$ und $Y = B_2 + B_3$. Da die Würfe unabhängig sind, bleibt bei der Kovarianz nur der gemeinsame Term B_2 übrig: $\text{Cov}(X, Y) = \text{Var}(B_2) = 1/4$.

5. Stichproben und Stichprobenmittel

Seien $X_1, \dots, X_n$ unabhängig und identisch verteilt (*iid*). Dies nennt man eine **Zufallsstichprobe**.

📖 Stichprobenmittel (Sample Mean)

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

Eigenschaften:

- Wenn $\mathbb{E}X_1 = \mu$ und $\text{Var}(X_1) = \sigma^2$, dann gilt:
 - $\mathbb{E}\bar{X}_n = \mu$
 - $\text{Var}(\bar{X}_n) = \frac{\sigma^2}{n}$ (Die Streuung des Mittels sinkt mit steigendem n)
- Wenn $X_i \sim \mathcal{N}(\mu, \sigma^2)$, dann ist auch $\bar{X}_n \sim \mathcal{N}(\mu, \frac{\sigma^2}{n})$.

6. Gesetz der großen Zahlen (LLN)


Das Gesetz der großen Zahlen besagt, dass das Stichprobenmittel $\bar{X}_n$ mit hoher Wahrscheinlichkeit sehr nahe am Erwartungswert μ liegt, wenn n groß wird.

Gesetz der großen Zahlen

Für eine Folge von *iid* Zufallsvariablen mit endlicher Varianz gilt für jedes $\epsilon > 0$:

$$\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| < \epsilon) = 1$$

Das bedeutet: $\bar{X}_n$ konvergiert in Wahrscheinlichkeit gegen den Erwartungswert $\mathbb{E}X_1$.




7. Histogramme

Ein Histogramm visualisiert die Verteilung von Beobachtungen.

- **Frequency:** Balkenhöhe = Anzahl der Beobachtungen pro Bin.
- **Density:** Die Gesamtfläche unter den Balken ist 1. Dies erlaubt den Vergleich mit Dichtefunktionen.

Zusammenhang zum LLN

Das Gesetz der großen Zahlen impliziert, dass sich das Dichte-Histogramm bei steigender Stichprobengröße der theoretischen Dichtefunktion der Verteilung annähert.



8. Zentraler Grenzwertsatz (CLT)

Der CLT ist eines der wichtigsten Konzepte der Statistik. Er erklärt, warum die Normalverteilung so oft vorkommt.

Zentraler Grenzwertsatz


Für eine Folge von *iid* Zufallsvariablen X_i mit endlicher Varianz konvergiert das standardisierte Stichprobenmittel gegen die Standardnormalverteilung $\mathcal{N}(0, 1)$:

$$\sqrt{n}(\bar{X}_n - \mathbb{E}X_1) \xrightarrow{d} \mathcal{N}(0, \text{Var}(X_1))$$

In der Praxis (für großes n):

- Mittelwert: $\bar{X}_n \approx \mathcal{N}(\mu, \sigma^2/n)$
- Summe: $S_n = \sum X_i \approx \mathcal{N}(n\mu, n\sigma^2)$
- Standardisierte Form: $\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \approx \mathcal{N}(0, 1)$

Histograms of standardized means $\sqrt{n}(\bar{X}_n - 1)$ with *standard normal density in red*
Based on 10 000 simulations of the mean $\bar{X}_n$



9. Normalapproximation (CLT Anwendungen)

9.1 Binomialverteilung → Normalverteilung

Eine Binomialverteilung $S_n \sim \text{Bin}(n, p)$ kann als Summe von n Bernoulli-Trials betrachtet werden.

$$S_n \approx \mathcal{N}(np, np(1-p))$$


🔗 Faustregel

Die Approximation gilt als brauchbar, wenn $10 \leq \min(np, n(1-p))$.

Stetigkeitskorrektur (Continuity Correction):

Da wir eine diskrete Verteilung durch eine stetige ersetzen, addieren/subtrahieren wir 0.5:

$$P(a \leq S_n \leq b) \approx \Phi\left(\frac{b + \frac{1}{2} - np}{\sqrt{np(1-p)}}\right) - \Phi\left(\frac{a - \frac{1}{2} - np}{\sqrt{np(1-p)}}\right)$$



9.2 Poissonverteilung → Normalverteilung

Für $X \sim \text{Poisson}(\lambda)$ gilt:

$$Poisson(\lambda) \approx \mathcal{N}(\lambda, \lambda)$$

- **Faustregel:** Brauchbar, wenn $\lambda > 15$.
- **Berechnung mit Stetigkeitskorrektur:**

$$P(a \leq X \leq b) \approx \Phi\left(\frac{b + \frac{1}{2} - \lambda}{\sqrt{\lambda}}\right) - \Phi\left(\frac{a - \frac{1}{2} - \lambda}{\sqrt{\lambda}}\right)$$

Moderne Sichtweise

Dank Software wie R sind diese Approximationen heute weniger kritisch; man sollte nach Möglichkeit die exakten Verteilungen verwenden.

I6 - Deskriptive Statistik & Grundlagen der Punktschätzung

1. Einführung: Statistik vs. Wahrscheinlichkeitstheorie

Wahrscheinlichkeitstheorie und Statistik sind zwei Seiten derselben Medaille, unterscheiden sich aber in ihrer Herangehensweise:

- **Wahrscheinlichkeitstheorie:** Man kennt die **Grundgesamtheit (Population)** und berechnet Wahrscheinlichkeiten für Stichproben (Teilmengen).
 - *Vom Allgemeinen zum Spezifischen.*
- **Statistik:** Man beobachtet **Stichproben (Daten)** und zieht daraus Rückschlüsse auf die Grundgesamtheit.
 - *Vom Spezifischen zum Allgemeinen.*

Definitionen

- **Wahrscheinlichkeit:** Quantifizierung der Chance, dass ein Ereignis eintritt.
- **Statistik:** Disziplin zur Erhebung, Analyse, Interpretation und Präsentation von Daten.

2. Datenskalen (Levels of Measurement)

Bevor man Daten analysiert, muss man wissen, welcher Skala sie angehören:

Datentyp	Beschreibung	Beispiele
Kategorial (Nominal)	Keine Ordnung, nur Kategorien.	Geschlecht, Haustierart, Ja/Nein-Antworten.
Ordinal	Geordnete Kategorien (sortierbar), aber keine messbaren Abstände.	Zufriedenheit (sehr unzufrieden bis sehr zufrieden), Erfahrung (Anfänger bis Experte).
Kontinuierlich (Metrisch)	Werte können verglichen, ranggeordnet und Abstände berechnet werden. (Intervall-/Ratioskala)	Verkaufspreis, Gewicht, Stromverbrauch in kWh.


3. Datenvisualisierung (Eindimensional)

3.1 Strip Chart (Streifendiagramm)

Ein Strip Chart zeigt jeden einzelnen Datenpunkt entlang einer Achse.

- **Vorteile:** Man sieht die volle Verteilung und Clusterbildung.

- **Jitter:** Ein kleiner zufälliger Versatz senkrecht zur Datenachse, um überlappende Punkte sichtbar zu machen. Die Position auf der "Jitter-Achse" hat keine statistische Bedeutung.



At first glance, we can observe the distribution of the dataset:

- Most values cluster around a typical value (between 48 and 52).
- The minimum value corresponds to the employee with the fewest working hours (around 41).
- The maximum value corresponds to the employee with the most working hours (around 61).

3.2 Histogramme


Histogramme teilen Daten in Intervalle (**Bins**) ein und zeigen die Häufigkeit pro Intervall.

- Helfen dabei, die **Form** (symmetrisch, schief), **Streuung** und **Ausreißer** zu erkennen.
- **Absolute Häufigkeit:** Die Höhe der Balken gibt an, wie viele Beobachtungen in das Intervall fallen.
- **Normalisierte Histogramme (Dichte):** Hier wird die y-Achse so skaliert, dass die **Gesamtfläche des Histogramms gleich 1** ist. Das ist nützlich, um Gruppen mit unterschiedlichen Stichprobengrößen (n) zu vergleichen.

 **Umrechnung zur Dichte D_i**

$$D_i = \frac{H_i}{n \cdot \Delta}$$

Wobei H_i die absolute Häufigkeit und Δ die Intervallbreite ist.



- A **histogram** is a graphical tool for visualizing the distribution of data.
- It displays how often observations fall into different intervals (bins).
- Helps to identify the overall shape, spread, and potential outliers.

4. Statistische Kennzahlen (Statistics)

4.1 Grundbegriffe

- **Zufallsvariablen:** Werden mit Großbuchstaben bezeichnet (z. B. $X_1, X_2, \dots, X_n$). Vor der Datenerhebung sind sie zufällig.
- **Realisierungen (Daten):** Werden mit Kleinbuchstaben bezeichnet (z. B. $x_1, x_2, \dots, x_n$). Das sind die festen, beobachteten Werte.
- **Statistik:** Eine Funktion der Daten $T(X)$, die einen Aspekt des Datensatzes zusammenfasst. Eine Statistik ist selbst eine Zufallsvariable.

4.2 Lagemaße & Streuungsmaße

Die wichtigsten Maße für bellenförmige (symmetrische) Verteilungen:

- **Empirisches Mittel (Mean):** Der Durchschnittswert. Geometrisch gesehen der "Schwerpunkt" der Daten.
 - Zufallsvariable:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

- Beobachteter Wert:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

- **Empirische Varianz (s^2):** Maß für die Streuung.
 - Formel (korrigiert):

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

- **Hinweis:** Der Faktor $n - 1$ (Bessel-Korrektur) sorgt für Unverzerrtheit.
- **Empirische Standardabweichung (s):** Die Wurzel aus der Varianz. Sie hat dieselbe Einheit wie die Daten.

- $s = \sqrt{s^2}$

i Die 68-95-99.7 Regel (Normalverteilung)

Bei einer Normalverteilung liegen:

- ca. 68% der Daten innerhalb von $\bar{x} \pm s$
- ca. 95% der Daten innerhalb von $\bar{x} \pm 2s$
- ca. 99.7% der Daten innerhalb von $\bar{x} \pm 3s$

5. Schiefe Verteilungen & Quantile

Wenn Daten **nicht bellenförmig** (z. B. rechtsschief) sind, sind Mittelwert und Standardabweichung schlechte Deskriptoren. Man nutzt stattdessen den **Median** und den **IQR**.

5.1 Empirische Quantile (q_p)


Ein Wert q_p , für den gilt: Mindestens ein Anteil p der Daten ist $\leq q_p$ und mindestens ein Anteil $1 - p$ ist $\geq q_p$.

- **Median ($p = 0.5$):** Teilt die Daten in zwei Hälften. Bei rechtsschiefen Verteilungen liegt der Mittelwert rechts vom Median.
- **1. Quartil ($Q1, p = 0.25$):** 25% der Daten sind kleiner oder gleich diesem Wert.
- **3. Quartil ($Q3, p = 0.75$):** 75% der Daten sind kleiner oder gleich diesem Wert.

5.2 Boxplot

Ein Boxplot visualisiert die "Five-Number Summary": Minimum, $Q1$, Median, $Q3$, Maximum.

- **Box:** Reicht von $Q1$ bis $Q3$.
- **Interquartilsabstand (IQR):** Länge der Box ($Q3 - Q1$). Ein Maß für die Streuung der mittleren 50% der Daten.
- **Whiskers (Antennen):** Erstrecken sich standardmäßig bis zum extremsten Datenpunkt, der maximal $1.5 \cdot IQR$ von der Box entfernt ist.
- **Ausreißer:** Punkte außerhalb der Whiskers werden einzeln gezeichnet.



- Summarizes the data using five key statistics:
 - Minimum:** smallest value
 - 1st quartile (Q1):** 25% of data $\leq Q1$, 75% $\geq Q1$
 - Median (m):** 50% of data $\leq m$, 50% $\geq m$
 - 3rd quartile (Q3):** 75% of data $\leq Q3$, 25% $\geq Q3$
 - Maximum:** largest value
- Median (m) indicates the central location of the observations

6. Zusammenhänge: Scatterplots & Korrelation

Um die Beziehung zwischen **zwei** kontinuierlichen Variablen zu analysieren:

- Scatterplot:** Visualisierung von (x, y) Paaren.
 - Richtung:** Positiv (beide steigen) oder Negativ (einer steigt, einer fällt).
 - Form:** Linear oder nicht-linear (gekrümmt).
 - Stärke:** Wie eng liegen die Punkte an einer Linie?
- Pearson Korrelationskoeffizient (r):**
 - Misst die Stärke und Richtung eines **linearen** Zusammenhangs.
 - Wertebereich: $-1 \leq r \leq 1$.
 - $r = 1$: Perfekt positiver linearer Zusammenhang.
 - $r = -1$: Perfekt negativer linearer Zusammenhang.
 - $r = 0$: Kein **linearer** Zusammenhang (nicht-lineare Muster können trotzdem existieren!).

⚠ Wichtig

Korrelation impliziert keine Kausalität! Ein starkes r bedeutet nicht zwingend, dass x die Ursache für y ist. Visualisiere Daten immer zuerst per Scatterplot, bevor du r berechnest.

7. Grundlagen der Punktschätzung (Point Estimation)

7.1 Stichprobenverteilung (Sampling Distribution)

Da eine Statistik (z. B. $\bar{X}$) von einer Zufallsstichprobe abhängt, ist sie selbst eine Zufallsvariable mit einer eigenen Verteilung.

- **Standardfehler (Standard Error, SE):** Die Standardabweichung der Stichprobenverteilung einer Statistik. Er gibt an, wie stark die Schätzung von Stichprobe zu Stichprobe schwankt.
 - Für den Mittelwert gilt:

$$SE(\bar{X}) = \frac{\sigma}{\sqrt{n}}$$

- Geschätzter Standardfehler (wenn σ unbekannt):

$$\hat{SE}(\bar{X}) = \frac{s}{\sqrt{n}}$$

7.2 Punktschätzer vs. Schätzwert

- **Punktschätzer ($\hat{\theta}$):** Eine Rechenvorschrift (Statistik), um einen unbekannten Parameter θ zu approximieren (z. B. die Formel für $\bar{X}$).
- **Punktschätzung ($\hat{\theta}_{obs}$):** Der konkrete Zahlenwert, der nach Einsetzen der beobachteten Daten herauskommt.

7.3 Unverzerrtheit (Unbiasedness)

Ein Schätzer heißt **unverzerrt**, wenn sein Erwartungswert dem wahren Parameter entspricht:

$$\mathbb{E}[\hat{\theta}] = \theta$$

- **Bias:** Die systematische Abweichung $Bias(\hat{\theta}) = \mathbb{E}[\hat{\theta}] - \theta$.
- Ein unverzerrter Schätzer "trifft das Ziel im Durchschnitt".

8. R-Code Referenz

Nützliche R-Befehle

```
# Einfache Grafiken
stripchart(y, method = "jitter", pch = "+") # Streifendiagramm
hist(y, breaks = 10, prob = TRUE)           # Histogramm (prob=TRUE
für Dichte)
boxplot(y, horizontal = TRUE)                # Boxplot
plot(x, y)                                   # Scatterplot

# Kennzahlen
mean(x)   # Arithmetisches Mittel
var(x)    # Empirische Varianz (n-1)
sd(x)     # Empirische Standardabweichung
median(x) # Median
```

```
quantile(x, probs = c(0.25, 0.75)) # Quartile  
cor(x, y) # Pearson Korrelation
```

17 - Konfidenzintervalle & Hypothesentests

1. Grundlagen der Konfidenzintervalle (CI)

Punkt-Schätzer (Reminder)

- Ein **Punkt-Schätzer** eines Parameters θ ist eine Statistik $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$, die aus einer Stichprobe berechnet wird, um den unbekannten Parameter zu approximieren.
- Da er auf Zufallsdaten basiert, ist der Schätzer selbst eine **Zufallsvariable** mit einer Stichprobenverteilung.
- Punkt-Schätzung**: Der numerische Wert $\hat{\theta}_{obs} = \hat{\theta}(x_1, \dots, x_n)$, der bei Auswertung konkreter Daten entsteht.
- Beispiel Stichprobenmittel**: $\hat{\mu} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$
- Erwartungstreue (Unbiasedness)**: $\mathbb{E}[\hat{\theta}] = \theta$. Eine wünschenswerte Eigenschaft, die besagt, dass der Schätzer im Mittel den wahren Wert trifft (gilt nicht immer!).

Motivation: Warum Konfidenzintervalle?

Ein einzelner Punkt-Schätzer variiert von Stichprobe zu Stichprobe.

☰ Beispiel Münzwurf

Bei 20 Würfeln einer fairen Münze erwarten wir 10-mal "Kopf". In Simulationen erhält man jedoch Werte wie 9, 11, 8, 14, 7 usw. Das Mittel vieler Simulationen (z.B. 10.06) liegt nah am Erwartungswert, ist aber selten exakt gleich.

Anstatt nur eine Zahl zu nennen, geben wir einen **Bereich plausibler Werte** an.

- Konfidenzintervall (CI)**: Quantifiziert die Unsicherheit über die Lage eines Populationsparameters basierend auf einer Stichprobe.
- Es ist eine **Statistik**, also ein zufälliges Intervall (ein Zufallsvektor mit zwei Komponenten).

Allgemeine Form und Definition

Sei $X = (X_1, \dots, X_n)^T$ eine Stichprobe. Ein CI für den Parameter θ zum Konfidenzniveau $1 - \alpha$ ist das zufällige Intervall:

$$CI_{1-\alpha}(X) = [L(X), R(X)]$$

Es wird durch die Statistiken $L(X)$ (links) und $R(X)$ (rechts) so bestimmt, dass gilt:

$$Pr[L(X) \leq \theta \leq R(X)] \geq 1 - \alpha$$

🔗 Korrekte Interpretation


- Das Intervall überdeckt den wahren Parameter mit der Wahrscheinlichkeit $(1 - \alpha) \times 100\%$.
- Nach der Realisierung** (wenn konkrete Zahlen vorliegen): Wir können nicht mehr von Wahrscheinlichkeit sprechen (der feste Parameter liegt entweder drin oder nicht).

- **Bedeutung:** Würden wir die Stichprobenziehung oft wiederholen, würden ca. $(1 - \alpha) \times 100\%$ der so konstruierten Intervalle den wahren Parameter enthalten.

Example: Confidence Intervals in Repeated Sampling

- We simulate many random samples from a population with a known mean μ and standard deviation σ .
- For each sample, we compute the sample mean $\bar{x}$ and its 95% confidence interval:

$$\bar{x} \pm z_{0.975} \cdot \frac{\sigma}{\sqrt{n}}.$$



2. Konstruktion von Konfidenzintervallen

CI via Punkt-Schätzer

Meist wird ein Intervall symmetrisch um einen Schätzer definiert:

$$CI_{1-\alpha}(X) = [\hat{\theta}(X) - \text{margin}_{1-\alpha}(X), \hat{\theta}(X) + \text{margin}_{1-\alpha}(X)]$$

- $\text{margin}_{1-\alpha}$: Fehlermarge (Margin of Error).
- Bei **bell-shaped (symmetrischen) Verteilungen**:

$$Pr[L(X) \leq \theta \leq \hat{\theta}(X)] = Pr[\hat{\theta}(X) \leq \theta \leq R(X)] = \frac{1-\alpha}{2}.$$

Fall 1: Mittelwert bei bekannter Varianz (σ^2 bekannt)

Basierend auf dem Zentralen Grenzwertsatz (CLT) ist der Stichprobenmittelwert für großes n approximativ normalverteilt: $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$.

- Für 95% Konfidenz liegen die kritischen Werte bei $z_{0.025} = -1.96$ und $z_{0.975} = 1.96$.
- **Formel:**

$$\bar{x} \pm z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$


- **Standardfehler (Standard Error):** $SE(\bar{X}) = \frac{\sigma}{\sqrt{n}}$.

Confidence Interval for the Mean with Known Variance

- Let $X_1, X_2, \dots, X_n$ be a random sample from a population with mean μ and known variance σ^2
- By the **Central Limit Theorem (CLT)**, for large n , the distribution of the sample mean can be approximated by

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

- For a normal distribution, approximately 95% of the probability mass lies within 1.96 standard deviations of the mean, that is, between $z_{0.025} = -1.96$ and $z_{0.975} = 1.96$.



Fall 2: Mittelwert bei unbekannter Varianz (σ^2 unbekannt)

Wenn σ unbekannt ist, nutzen wir die Stichprobenstandardabweichung S als Schätzer:

- **Geschätzter Standardfehler:** $\hat{SE}(\bar{X}) = \frac{S}{\sqrt{n}}$.
- Wir nutzen die **Student's t-Verteilung** mit $n - 1$ Freiheitsgraden (df).


Herleitung der t-Statistik

1. Stichprobenvarianz $S^2 = \frac{1}{n-1} \sum_{j=1}^n (X_j - \bar{X})^2$ folgt einer skalierten Chi-Quadrat-Verteilung: $\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$.
2. $\bar{X}$ und S^2 sind bei Normalverteilung unabhängig.
3. Die Statistik $T(X) = \frac{\bar{X} - \mu}{S/\sqrt{n}}$ folgt einer t_{n-1} -Verteilung.

Formel für das t-Intervall:

$$CI_{1-\alpha} = \bar{x} \pm t_{\alpha/2, n-1} \cdot \frac{s}{\sqrt{n}}$$

t-Statistic Confidence Intervals



3. Grundlagen des Hypothesentests

Grundidee

Ein Hypothesentest ist eine Regel, die entscheidet, für welche Stichprobenwerte eine Nullhypothese H_0 akzeptiert oder abgelehnt wird.

- **Nullhypothese (H_0)**: Die Aussage über die Population, die wir prüfen wollen (oft der "Status Quo" oder "kein Effekt").
- **Alternative (H_1)**: Die Gegenhypothese.
- **Teststatistik $W(X)$** : Eine Funktion der Stichprobe, die die Kompatibilität der Daten mit H_0 misst.

Testarten

1. **Linksseitig**: $H_0 : \mu \geq \mu_0$ vs. $H_1 : \mu < \mu_0$
2. **Rechtsseitig**: $H_0 : \mu \leq \mu_0$ vs. $H_1 : \mu > \mu_0$
3. **Zweiseitig**: $H_0 : \mu = \mu_0$ vs. $H_1 : \mu \neq \mu_0$

Der p-Wert (p-value)

Der p-Wert $p(X)$ (zwischen 0 und 1) quantifiziert die Diskrepanz zwischen Daten und H_0 .

- **Definition:** Die Wahrscheinlichkeit, unter der Annahme, dass H_0 wahr ist, ein Ergebnis zu erhalten, das mindestens so extrem ist wie das beobachtete.
- **Entscheidungsregel:**
 - $p \leq \alpha$: H_0 ablehnen (statistisch signifikant).
 - $p > \alpha$: H_0 nicht ablehnen.

Der z-Test (Beispiel: Retail Scenario)

Annahme: Stichprobe $X_i \sim N(\mu, \sigma^2)$ mit bekanntem σ^2 .

- **Teststatistik:** $Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim N(0, 1)$ unter H_0 .
- **Signifikanzniveau α :** Vorab gewählte Irrtumswahrscheinlichkeit (meist 0.05, 0.01 oder 0.001).

Modellannahmen

In der Praxis ist ein bekanntes σ unrealistisch. Bei großen Stichproben erlaubt der CLT jedoch die Annahme einer Normalverteilung der Teststatistik. Bei unbekanntem σ nutzt man den t-Test.

4. Fehlerarten und Teststärke (Power)

Beim Testen können zwei Arten von Fehlern auftreten, da wir nur eine Stichprobe betrachten:

Realität \ Entscheidung	H_0 nicht ablehnen	H_0 ablehnen
H_0 ist wahr	Korrekt ($1 - \alpha$)	Typ I Fehler (α)
H_0 ist falsch	Typ II Fehler (β)	Korrekt / Power ($1 - \beta$)

- **Typ I Fehler (Signifikanzniveau α):** H_0 wird abgelehnt, obwohl sie wahr ist ("falscher Alarm").
- **Typ II Fehler (β):** H_0 wird nicht abgelehnt, obwohl sie falsch ist ("Übersehen eines Effekts").
- **Power ($1 - \beta$):** Die Wahrscheinlichkeit, einen tatsächlich vorhandenen Effekt auch zu finden.

Trade-off

Verringert man α (strengerer Test), erhöht man automatisch das Risiko für einen Typ II Fehler (β), sofern der Stichprobenumfang gleich bleibt.


Ablehnungsbereich (Rejection Region)

Der Bereich der Teststatistik, der zur Ablehnung von H_0 führt.


- Beispiel z-Test (zweiseitig, $\alpha = 0.05$): Ablehnung, wenn $|z| > 1.96$.

Errors and Test Power in Hypothesis Testing


H_0 True: Correctly Accepted




H_0 True: Type I Error



H_0 False: Type II Error



H_0 False: Correctly Rejected



Wichtige Fehlinterpretationen

- "Nicht ablehnen" bedeutet **nicht**, dass H_0 wahr ist. Es bedeutet nur, dass die Daten nicht ausreichen, um sie zu widerlegen.
- "Ablehnen" bedeutet **nicht**, dass H_0 mit Sicherheit falsch ist, sondern nur, dass die Daten unter H_0 sehr unwahrscheinlich sind.

l8 - Einführung in die Hypothesentests

Ein **Hypothesentest** ist ein Verfahren, um basierend auf einer Stichprobe aus einer Grundgesamtheit zu entscheiden, welche von zwei komplementären Hypothesen wahr ist.

Grundbegriffe

- **Hypothese:** Eine Aussage über einen Populationsparameter.
- **Nullhypothese (H_0):** Die Hypothese, die meist den Status Quo, bisherige Standards oder allgemein akzeptierte Zustände darstellt. Man versucht oft, diese zu widerlegen.
- **Alternative Hypothese (H_1):** Stellt neue Behauptungen oder Effekte dar, die man nachweisen möchte.
- **Teststatistik ($W(X)$):** Eine Funktion der Stichprobe $W(X_1, \dots, X_n)$, die die Kompatibilität zwischen den Daten und der Nullhypothese misst.
- **Ablehnungsbereich (Kritischer Bereich):** Teilmenge des Stichprobenraums, für die H_0 abgelehnt wird.
- **Annahmebereich:** Das Komplement des Ablehnungsbereichs.

Statistische Hypothese

Eine statistische Hypothese behauptet, dass die wahre unbekannte Verteilung in einem Teilmodell des betrachteten statistischen Modells liegt. Wenn ein Parameterraum Θ existiert, besagt die Hypothese, dass der wahre Parameterwert in einer Teilmenge Θ_i von Θ liegt.

Einseitige vs. Zweiseitige Tests

Je nach Fragestellung unterscheidet man bei Tests für den Populationsmittelwert μ :

- **Linksseitiger Test:** $H_0 : \mu \geq \mu_0$ gegen $H_1 : \mu < \mu_0$
- **Rechtsseitiger Test:** $H_0 : \mu \leq \mu_0$ gegen $H_1 : \mu > \mu_0$
- **Zweiseitiger Test:** $H_0 : \mu = \mu_0$ gegen $H_1 : \mu \neq \mu_0$

P-Wert (p-value)

Der **P-Wert** $p(X)$ ist eine Teststatistik mit Werten zwischen 0 und 1. Er misst, wie "überraschend" die beobachtete Stichprobe unter der Annahme ist, dass H_0 wahr ist.

- **Bedeutung:** Kleine Werte von $p(X)$ liefern Evidenz gegen H_0 .
- **Entscheidung:** Ein Test auf dem Signifikanzniveau α lehnt H_0 genau dann ab, wenn $p(X) \leq \alpha$.
- **Berechnung (unter H_0):**
 - Linksseitig: $\mathbb{P}(Z < z)$
 - Rechtsseitig: $\mathbb{P}(Z > z)$
 - Zweiseitig: $2 \cdot \min\{\mathbb{P}(Z > |z|)\}$

Große Stichproben: Der Z-Test

Bei großen Stichproben (typischerweise $n > 30$ oder 40) kann der **Zentrale Grenzwertsatz (CLT)** angewendet werden. Dies erlaubt Tests für den Mittelwert beliebiger Verteilungen (nicht zwingend normalverteilt).

Zentraler Grenzwertsatz

Wenn $X_1, \dots, X_n$ eine Zufallsstichprobe aus einer Verteilung mit Mittelwert μ und Varianz σ^2 sind, dann gilt für großes n :

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim \mathcal{N}(0, 1)$$

Wobei $S = \sqrt{\frac{\sum (X_i - \bar{X})^2}{n-1}}$ die Stichprobenstandardabweichung ist.

Konfidenzintervalle (CI) für großes n

Ein $100(1 - \alpha)\%$ CI für μ berechnet sich als:

$$\bar{x} \pm z_{\alpha/2} \cdot \frac{s}{\sqrt{n}}$$

Zusammenhang CI und Hypothesentest

Das $100(1 - \alpha)\%$ Konfidenzintervall ist das Komplement des Ablehnungsbereichs eines zweiseitigen Tests zum Niveau α . Enthält das Intervall den hypothetischen Wert μ_0 , kann H_0 nicht abgelehnt werden.

Kleine Stichproben: Der t-Test

Wenn die Stichprobe klein ist ($n \leq 30$), muss die Verteilung der Daten normalverteilt sein ($X_i \sim \mathcal{N}(\mu, \sigma^2)$), um exakte Tests durchzuführen.

Student's t-Verteilung


Da σ meist unbekannt ist und durch S geschätzt werden muss, entsteht zusätzliche Unsicherheit. Die Teststatistik folgt dann einer t-Verteilung mit $n - 1$ Freiheitsgraden (df):

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t(n - 1)$$

Eigenschaften der t-Verteilung

- Symmetrisch um 0.
- **Heavier Tails:** Sie hat "fettne" Enden als die Standardnormalverteilung, was die Unsicherheit der Schätzung von σ widerspiegelt.
- Für $n \rightarrow \infty$ nähert sich die t-Verteilung der Standardnormalverteilung $\mathcal{N}(0, 1)$ an.

$\mathcal{N}(0, 1)$ vs t -Distribution



Test-Roadmap (Entscheidungshilfe)


Fall	Bedingung	Teststatistik	Verteilung unter H_0
Großes n	$n > 30/40$	$Z = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$	$\approx \mathcal{N}(0, 1)$
Kleines n	Normalverteilung, σ^2 bekannt	$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$	$\mathcal{N}(0, 1)$
Kleines n	Normalverteilung, σ^2 unbekannt	$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$	$t(n - 1)$

Zusammenfassung Ablehnungsbereiche und P-Werte

Werte für einen gegebenen Wert α und beobachtete Teststatistik t (bzw. z):

H_1	Ablehnungsbereich (t-Test)	P-Wert (t-Test)
$\mu > \mu_0$	$t > t_\alpha(n - 1)$	$\mathbb{P}(T > t)$
$\mu < \mu_0$	$t < -t_\alpha(n - 1)$	$\mathbb{P}(T < t)$
$\mu \neq \mu_0$	\$	t

Visual Comparison of t -test vs z -test

Acceptance and Rejection Regions ($\alpha = 0.05$)

Anwendungsbeispiele

1. "Can Money Buy Love?" (Große Stichprobe)

- Untersuchung von Wertschätzung (Appreciation) bei Geschenken.
- $n = 237$. Stichprobenmittelwert $\bar{x} \approx 3.025$.
- Da n groß ist, wurde das CLT genutzt, um ein 95% CI von $[2.81, 3.24]$ zu berechnen.

2. Stock Screeners (Kleine Stichprobe)

- $n = 13$ (Investmentrenditen).
- Frage: Ist die durchschnittliche Rendite $\mu > 0$?
- Da n klein und σ unbekannt, wurde ein **t-Test** durchgeführt.
- Ergebnis: $t \approx 5.06$, p -wert ≈ 0.00003 . H_0 wird abgelehnt; Stock Screeners performen besser als der S&P 500.

3. Radonbelastung in ägyptischen Gräbern

- $n = 12$ Gräber. Sicherheitslimit $\mu = 6000 \text{ Bq/m}^3$.
- Test: $H_0 : \mu \geq 6000$ (Status Quo: gefährlich) gegen $H_1 : \mu < 6000$ (sicher).
- **Anmerkung:** In den Folien wird auch die Variante $H_0 : \mu \leq 6000$ vs $H_1 : \mu > 6000$ diskutiert, um zu prüfen, ob ein Schwellenwert überschritten wurde.

- **Wichtig:** Der t-Test setzt Normalverteilung voraus. Die Daten waren hier jedoch rechtsschief mit Ausreißern.

⚠ Überprüfung der Annahmen


Vor einem t-Test sollte die Normalverteilung geprüft werden (z.B. via Histogramm oder Boxplot). Bei starker Schiefe oder Ausreißern ist das Ergebnis fragwürdig.

Application

Checking Assumptions

- The population distribution should be approximately normal.

How to check: The data are right-skewed with large outliers; normality assumption is questionable.



Berechnungen in R

Wichtige Funktionen für die t-Verteilung:

- `dt(y, df)`: Dichtefunktion (pdf).
- `pt(y, df)`: Verteilungsfunktion (cdf).
- `qt(p, df)`: Quantilfunktion.
- `rt(n, df)`: Zufallszahlen generieren.

Beispiel t-Test manuell:

```
t_stat <- (xbar - mu0) / (s / sqrt(n))
p_val <- 1 - pt(t_stat, df = n - 1)
```

Calculations in R

```
screeners=c(9.0, -0.1, -1.6, 14.6, 16.0, 7.7, 19.9, 9.8, 3.2, 24.8, 17.6, 10.7, 9.1)
n=length(screeners)

xbar=mean(screeners) # sample mean
s=sd(screeners) # sample st. dev.
mu0=0

t=(xbar-mu0)/(s/sqrt(n))
t
[1] 5.060398

pval=1-pt(n-1,t)
pval
[1] 3.277494e-05
```

- The p -value=0.0000327 of the test statistic is very small
- The probability the data support the hypothesized value of μ under the null is tiny. Thus, we reject the null in favor of the alternative.
- We conclude the stock screeners beat S & P 500.

l9 - Hypothesentests & Fehlerarten

In der Statistik nutzen wir Hypothesentests, um Behauptungen über Grundgesamtheiten zu prüfen.

Null- und Alternativhypothese

- **Nullhypothese (H_0):** Die Behauptung, die als wahr angenommen wird, solange die Daten keine überzeugenden Beweise für das Gegenteil liefern. Sie spiegelt meist den **Status Quo** wider.
- **Alternativhypothese (H_1):** Die Forschungshypothese, die nur akzeptiert wird, wenn die Daten starke Beweise für ihre Richtigkeit liefern. Sie umfasst die Parameterwerte, für die Beweise gesucht werden.
- **Effekt erkennen:** In der Statistik ist "einen Effekt erkennen" gleichbedeutend mit dem **Ablehnen von H_0** .

Fehlerarten beim Testen

Beim Testen können zwei Arten von Fehlern auftreten, da wir auf Basis von Stichproben entscheiden:

Realität \ Entscheidung	H_0 ablehnen	H_0 nicht ablehnen
H_0 wahr	Fehler 1. Art (α)	Korrekte Entscheidung ($1 - \alpha$)
H_0 falsch	Korrekte Entscheidung / Power ($1 - \beta$)	Fehler 2. Art (β)

Errors and Test Power in Hypothesis Testing

Decision Reality	Reject H_0	Do not reject H_0
H_0 true	Type I error (α)	Correct decision ($1 - \alpha$)
H_0 false	Correct decision / Power ($1 - \beta$)	Type II error (β)


Definitions:

- **Type I error (α):** Rejecting H_0 when it is true. Probability controlled by the significance level. $\mathbb{P}_{H_0}(R) = \alpha$
- **Type II error (β):** Failing to reject H_0 when it is false. Probability depends on the true alternative. $\mathbb{P}_{H_1}(Ac) = \beta$
- **Power of the test ($1 - \beta$):** Probability of correctly rejecting H_0 when it is false.
- *Note:* Whether a specific error occurs cannot be known in practice, as hypotheses are theoretical assumptions.

Definitionen

- **Fehler 1. Art (α):** Ablehnen von H_0 , obwohl sie wahr ist. Die Wahrscheinlichkeit wird durch das **Signifikanzniveau** kontrolliert: $\mathbb{P}_{H_0}(R) = \alpha$.
- **Fehler 2. Art (β):** H_0 nicht ablehnen, obwohl sie falsch ist. Die Wahrscheinlichkeit $\mathbb{P}_{H_1}(Ac) = \beta$ hängt von der wahren Alternative ab.
- **Power der Tests ($1 - \beta$):** Die Wahrscheinlichkeit, H_0 korrekt abzulehnen, wenn sie falsch ist. Sie gibt die **Sensitivität** eines Tests an, einen echten Effekt zu finden.

Power of a Statistical Test




2. Die Teststärke (Power)

Die Power eines Tests wird durch vier Hauptfaktoren beeinflusst:

1. **Effektstärke (Effect Size):** Größere wahre Unterschiede erhöhen die Power.
2. **Stichprobenumfang (n):** Größere Stichproben reduzieren die Variabilität und erhöhen die Power.
3. **Signifikanzniveau (α):** Ein höheres α (z. B. 0.2 statt 0.05) erhöht die Power, aber auch das Risiko für einen Fehler 1. Art.
4. **Variabilität (σ):** Eine geringere Streuung in den Daten führt zu höherer Power.

Effect of the Significance Level (α)

- Increasing α (e.g., from 0.05 to 0.2) makes it easier to reject H_0 , **increasing the power** of the test, since the **rejection region (R)** becomes larger.
- Decreasing α (e.g., from 0.05 to 0.01) makes it harder to reject H_0 , **reducing the power**, since the **rejection region (R)** becomes smaller.



Effektstärke (Effect Size)

Die Effektstärke quantifiziert die Größe eines Unterschieds in Einheiten der Standardabweichung.

- Formel (einfacher Mittelwert):**

$$\theta = \frac{\mu - \mu_0}{\sigma}$$

- Faustregeln für θ :**
 - 0.2: kleiner Effekt
 - 0.5: mittlerer Effekt
 - 0.8: großer Effekt
- Zusammenhang:** Ein größerer Betrag von $|\theta|$ bedeutet eine stärkere Trennung zwischen H_0 und dem wahren Mittelwert $\rightarrow$ Power steigt.

Schätzer der Effektstärke

Da θ meist unbekannt ist, schätzen wir es mit d :

$$d = \frac{\bar{X} - \mu_0}{\sigma}$$

Bei bekanntem σ und großem n gilt für die Teststatistik Z :

$$Z = d\sqrt{n}$$

Folgen zu geringer Power (Underpowered Tests)

1. **Erhöhtes Risiko für False Negatives:** Echte Effekte werden oft übersehen.
2. **Überschätzte Effektstärken:** Nur ungewöhnlich große beobachtete Effekte werden signifikant ("Winner's Curse").
3. **Geringe Reproduzierbarkeit:** Ergebnisse sind instabil und Replikationen scheitern oft.

3. Vergleich zweier Grundgesamtheiten (Two-Sample Tests)

In der Informatik/Data Science oft relevant: Treatment vs. Control, Performance von Algorithmus A vs. B.

Fall 1: Unabhängige Stichproben (Groß: $n_1, n_2 > 30$)

Wenn die Stichproben groß genug sind, greift der Zentrale Grenzwertsatz (CLT). Wir nutzen den **z-Test**.

- **Schätzer für die Differenz:** $\bar{X}_1 - \bar{X}_2$
- **Standardfehler (SE):** $\hat{\sigma}_{\bar{x}_1 - \bar{x}_2} = \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}$
- **Konfidenzintervall (CI):**

$$CI_{1-\alpha} = (\bar{X}_1 - \bar{X}_2) \pm z_{\alpha/2} \cdot \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}$$

Interpretation des CI für Differenzen

- Nur positive Werte: $\mu_1 > \mu_2$
- Nur negative Werte: $\mu_1 < \mu_2$
- Enthält die Null: Kein statistisch signifikanter Unterschied nachweisbar.

Large-sample z-Tests for $\mu_1 - \mu_2$

For large sample sizes: $n_1, n_2 > 30$.

Test Type	Hypotheses	Rejection Region / p-value
Left-sided test	$H_0 : \mu_1 - \mu_2 = D_0$ $H_1 : \mu_1 - \mu_2 < D_0$	Reject $H_0 : z_{\text{obs}} \leq -z_\alpha$ p-value = $\mathbb{P}(Z \leq z_{\text{obs}})$
Right-sided test	$H_0 : \mu_1 - \mu_2 = D_0$ $H_1 : \mu_1 - \mu_2 > D_0$	Reject $H_0 : z_{\text{obs}} \geq z_\alpha$ p-value = $\mathbb{P}(Z \geq z_{\text{obs}})$
Two-sided test	$H_0 : \mu_1 - \mu_2 = D_0$ $H_1 : \mu_1 - \mu_2 \neq D_0$	Reject $H_0 : z_{\text{obs}} \geq z_{\alpha/2}$ p-value = $2 \times \mathbb{P}(Z \geq z_{\text{obs}})$

$$z_{\text{obs}} = \frac{(\bar{x}_1 - \bar{x}_2) - D_0}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

Fall 2: Unabhängige Stichproben (Klein: $n \leq 30$)

Hier ist der z-Test ungültig. Wir nutzen **Student's t-Test**.

A: Gleiche Varianzen ($\sigma_1^2 = \sigma_2^2$) $\rightarrow$ Pooled t-Test

Wir kombinieren ("poolen") die Varianzinformationen beider Gruppen.

- Pooled Variance:**

$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$$

- Teststatistik:**

$$T = \frac{\bar{X}_1 - \bar{X}_2 - D_0}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$

- Freiheitsgrade (df):** $n_1 + n_2 - 2$

B: Ungleiche Varianzen ($\sigma_1^2 \neq \sigma_2^2$) $\rightarrow$ Welch's t-Test

Wenn die Varianzen ungleich sind, ist der Pooled Test verzerrt. Welch's Test passt Standardfehler und Freiheitsgrade an.

- **Teststatistik:**

$$T = \frac{\bar{X}_1 - \bar{X}_2 - D_0}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}$$

- **Freiheitsgrade (ν):** Werden über die Welch-Satterthwaite Formel berechnet (meist niedriger als beim Pooled Test).

Vergleich: Welch vs. Pooled

- Die Freiheitsgrade ν beim Welch-Test sind immer $\leq df_{pooled}$ (Gleichheit nur bei identischen Varianzen und Stichprobenumfängen).
- Kleinere Freiheitsgrade $\rightarrow$ größere kritische Werte $\rightarrow$ konservativerer Test.

Fall 3: Abhängige / Gepaarte Stichproben (Paired Samples)

Wichtig: Wenn Datenpaare existieren (z. B. dieselben Versuchspersonen vor/nach einem Test oder Messungen am selben Tag), ist die Unabhängigkeit verletzt!


- **Lösung:** Wir berechnen die Differenzen $d_i = X_{1,i} - X_{2,i}$ für jedes Paar.
- **Verfahren:** Durchführung eines **Einstichproben-t-Tests** auf die Differenzen d_i .
- **Hypothesen:** $H_0 : \mu_d = 0$ vs. $H_1 : \mu_d \neq 0$.

Warum Paired Tests?

Bei den Restaurant-Verkaufszahlen im Skript korrelierten die täglichen Umsätze fast perfekt (0.998). Ein unabhängiger Test hätte den Unterschied nicht erkannt, da die hohe Varianz zwischen den Tagen (Wochenende vs. Wochentag) den Unterschied zwischen den Restaurants überdeckt hätte. Der Paired Test eliminiert diese "Tag-Varianz".

Comparing Mean Daily Sales of Two Restaurants

- Let us examine the potential dependence between the two samples.




- Correlation: 0.998.** The samples exhibit an almost perfect linear relationship.
- Although the restaurants are different and the dates were randomly selected, the sales were recorded **on the same dates** for both restaurants. Therefore, the independence of the samples cannot be assumed.

4. Entscheidungsregel (Zusammenfassung)

Um den richtigen Test zu wählen, folge diesem Pfad:

Stichprobenart	Bedingung	Test-Verfahren
Gepaart	Abhängige Paare	Einstichproben t-Test auf Differenzen
Unabhängig	Groß ($n > 30$)	z-Test
Unabhängig	Klein, gleiche Varianzen	Student's t-Test (pooled)
Unabhängig	Klein, ungleiche Varianzen	Welch's t-test

Decision Rule: Comparing Two Groups




l10 - Proportions

1. Ein-Stichproben-Test (One-Sample Test)

Motivation & Datenerhebung

Es soll eine Behauptung über einen Anteil in einer Grundgesamtheit geprüft werden.

- **Behauptung (p_0):** Der Anteil der Mathematik-Studierenden, die ein bestimmtes Betriebssystem nutzen, beträgt $p_0 = 40\%$.
- **Datensammlung:** Um diese Behauptung zu prüfen, führen Statistiker eine Umfrage durch.
- **Stichprobe:** $n = 49$ Studierende wurden gefragt ("Nutzen Sie dieses System?").
- **Datenart:** Kategoriale Daten (Antworten: "Ja" oder "Nein").
- the survey yields:
no, yes, yes, yes, no, yes, yes, yes, no, yes, no, yes, yes, yes, no, yes, yes,
no, yes, yes, yes, yes, yes, no, no, yes, no, no, yes, no, yes, yes, no, yes,
yes, yes, yes, no, yes, yes, yes, no, yes, no, yes, no, yes, yes, no



Deskriptive Statistik

Aus der Umfrage ergeben sich folgende Werte:

- **Absolute Häufigkeit (x):** $x = 33$ (Anzahl der "Erfolge"/Ja-Stimmen).
- **Relative Häufigkeit (Anteilsschätzer $\hat{p}$):**

$$\hat{p} = \frac{x}{n} = \frac{33}{49} \approx 67\%$$

🔍 Die Kernfrage

Ist der beobachtete Anteil $\hat{p}$ "weit genug weg" von der Behauptung p_0 , um diese abzulehnen?
Um das zu beantworten, benötigen wir ein statistisches Modell, das die **Variabilität** des Anteils berücksichtigt.

Das Statistische Modell

Wir modellieren die Antworten als Zufallsvariablen:

- **Bernoulli-Verteilung:** Jede Beobachtung $Y_1, \dots, Y_n$ ist iid (unabhängig und identisch verteilt) mit $Y_i \sim \text{Bernoulli}(p)$ für $p \in (0, 1)$.
 - 1 = Erfolg (Ja)
 - 0 = Misserfolg (Nein)
- **Relative Häufigkeit als Zufallsvariable:**

$$\hat{P} = \frac{1}{n} \sum_{i=1}^n Y_i$$


- **Zusammenhang zur Binomialverteilung:** Es gilt $n\hat{P} \sim \text{Binom}(n, p)$.

Approximation durch die Normalverteilung

Basierend auf dem **Zentralen Grenzwertsatz (CLT)** gilt für große n :

$$\frac{\hat{P} - p}{\sqrt{p(1-p)/n}} \xrightarrow{d} \mathcal{N}(0, 1)$$

(Das bedeutet: Der standardisierte Anteil folgt annähernd einer Standardnormalverteilung.)



Standardfehler (Standard Error)

Da die wahre Erfolgswahrscheinlichkeit p unbekannt ist, schätzen wir sie durch $\hat{P}$ im Nenner:

- **Erwartungswert:** $\mathbb{E}\hat{P} = p$
- **Varianz:** $\text{Var}(\hat{P}) = \frac{p(1-p)}{n}$
- **Standardfehler ($SE_{\hat{P}}$):**

$$SE_{\hat{P}} := \sqrt{\frac{\hat{P}(1 - \hat{P})}{n}}$$

Interpretation

$\hat{P}$ ist für große n näherungsweise normalverteilt. Eine Abweichung von $1 \times SE_{\hat{P}}$ ist zu erwarten, aber "viele" Standardabweichungen Differenz sind unwahrscheinlich, wenn die Hypothese stimmt.

Durchführung des asymptotischen Tests

Um eine Entscheidung zu treffen, nutzen wir das Signifikanzniveau α (meist 5%).

1. **Nullhypothese:** $H_0 : p = p_0$
2. **Teststatistik (Z):**

$$Z := \frac{\hat{P} - p_0}{SE_{\hat{P}}} \approx \mathcal{N}(0, 1)$$


3. **Konfidenzintervall (I):**

$$I := (\hat{P} - q_{1-\alpha/2} \cdot SE_{\hat{P}}, \hat{P} + q_{1-\alpha/2} \cdot SE_{\hat{P}})$$

Das Intervall überdeckt den Parameter p_0 mit einer Wahrscheinlichkeit von ca. $1 - \alpha$.

Beispielrechnung (Fortsetzung Motivation)

- $n = 49, x = 33, \hat{p} \approx 67\%$
- $p_0 = 40\%$
- $SE_{\hat{p}} = \sqrt{\frac{0.67(1-0.67)}{49}} \approx 7\%$
- **Beobachteter Z-Wert:** $z = \frac{0.67-0.40}{0.07} \approx 4.1$
- **Entscheidung:** Bei $\alpha = 5\%$ ist der kritische Wert $q_{0.975} \approx 1.96$. Da $|4.1| > 1.96$, liegt z im **Ablehnungsbereich** $R = (-\infty, -1.96] \cup [1.96, \infty)$.
- **Konfidenzintervall:** $\hat{I} \approx (54\%, 80\%)$. Da $p_0 = 40\%$ nicht im Intervall liegt, wird H_0 abgelehnt.



2. Zwei-Stichproben-Test (Two-Sample Test)

Motivation

Vergleich zweier Anteile p_1 und p_2 (z.B. Mathematik- vs. Informatik-Studierende).

- **Daten:**
 - Gruppe 1 (Math): $n_1 = 49, x_1 = 33 \implies \hat{p}_1 \approx 67.3\%$
 - Gruppe 2 (Inf): $n_2 = 64, x_2 = 37 \implies \hat{p}_2 \approx 57.8\%$
- **Hypothese:** $H_0 : p_1 = p_2$ (bzw. Differenz $p_2 - p_1 = 0$).

Modell & Teststatistik

Beide Gruppen werden als unabhängige Bernoulli-Experimente modelliert. Für große n_1, n_2 gilt:

- $\hat{P}_1 \approx \mathcal{N}(p_1, SE_{\hat{P}_1}^2)$
- $\hat{P}_2 \approx \mathcal{N}(p_2, SE_{\hat{P}_2}^2)$
- **Differenz:** $\hat{P}_2 - \hat{P}_1 \approx \mathcal{N}(p_2 - p_1, SE_{\hat{P}_1}^2 + SE_{\hat{P}_2}^2)$

Asymptotischer Testwert (Z):

$$Z := \frac{\hat{P}_2 - \hat{P}_1}{\sqrt{SE_{\hat{P}_1}^2 + SE_{\hat{P}_2}^2}} \approx \mathcal{N}(0, 1)$$

Struktur-Hinweis

Die Z-Statistik hat eine ähnliche Struktur wie die Welch-Statistik beim t-Test für Mittelwerte.

Beispielrechnung

- $z = \frac{37/64 - 33/49}{\sqrt{SE_{\hat{P}_1}^2 + SE_{\hat{P}_2}^2}} \approx -1.05$
- Da $|-1.05| < 1.96$ (für $\alpha = 5\%$), kann die Nullhypothese **nicht abgelehnt** werden.
- **Konfidenzintervall für die Differenz:** $\approx (-0.274, 0.083)$. Da die **Null** enthalten ist, ist der Unterschied nicht signifikant.

3. Umsetzung in R

In R wird für beide Tests die Funktion `prop.test()` verwendet.

Syntax

```
prop.test(x, n, p = NULL, ...)
```

- `x`: Anzahl der Erfolge (Vektor bei 2 Proben)
- `n`: Stichprobengröße (Vektor bei 2 Proben)

Beispiele aus der Vorlesung:

- **Ein-Stichproben-Test:** `prop.test(33, 49, 0.4)`
- **Zwei-Stichproben-Test:** `prop.test(c(37, 33), c(64, 49))`

Hinweis zu R-Ergebnissen

Die Werte in R können leicht von der Händischen Rechnung abweichen, da R standardmäßig eine **Stetigkeitskorrektur** (continuity correction) durchführt.

4. Wann ist n "groß genug"? (Gültigkeit)

Die Qualität der Normalapproximation sinkt, wenn:


1. Die Stichproben klein sind.
2. Der Anteil $\hat{p}$ sehr nah bei 0 oder 1 liegt.

Faustregeln (Rule of Thumb)


Damit der Test verlässlich ist, sollten folgende Bedingungen erfüllt sein:

- Gesamte Stichprobengröße $n \geq 30$.
- **Erfolgs- und Misserfolgsbedingung:**
 - $n\hat{p} > 15$
 - $n(1 - \hat{p}) > 15$

The *quality* of the *normal approximation* depends degrades with small group sizes n and when $\hat{p}$ (or p) are close to 0 or 1.



10 000 replicates of Z
for $n = 10$ with $p_0 = 10\%$
Poor approximation



10 000 replicates of Z
for $n = 40$ with $p_0 = 40\%$
Reasonable approximation

RULE OF THUMB: The total sample size should at least be 30 and for all frequencies should hold $n\hat{p} > 15$ and $n(1 - \hat{p}) > 15$ (Rough minimal conditions.)

(Oben: $n = 40, p = 0.4$ ist okay. Unten: $n = 10, p = 0.1$ zeigt eine schlechte Approximation.)

l11 - Goodness of fit & Independence

1. Der χ^2 -Anpassungstest (Goodness of Fit)

Der Anpassungstest prüft, ob die beobachteten Häufigkeiten in verschiedenen Kategorien signifikant von den unter einer Hypothese erwarteten Häufigkeiten abweichen.


Einstiegsbeispiel: Ist der Würfel fair?


Um zu prüfen, ob ein sechsseitiger Würfel fair ist (jede Seite hat $p = \frac{1}{6}$), gehen wir methodisch vor:

1. **Daten sammeln:** Wir werfen den Würfel $n = 120$ Mal.
2. **Kategorien:** Es gibt 6 Kategorien (die Farben/Seiten des Würfels).
3. **Beobachtung (O_i):** Wir zählen, wie oft jede Seite tatsächlich vorkommt.
4. **Erwartung (E_i):** Bei einem fairen Würfel erwarten wir pro Seite $120 \times \frac{1}{6} = 20$ Treffer.

Intuition

"Fair" bedeutet: Kein Ergebnis wird bevorzugt. Wenn der Würfel fair ist, sollten die beobachteten Werte (O_i) nah an den erwarteten Werten (E_i) liegen. Je größer die Abweichung, desto unfairer ist der Würfel wahrscheinlich.





Theoretische Grundlagen

Binomialverteilung (Reminder)

Wenn wir nur **zwei Kategorien** haben (Erfolg/Misserfolg), nutzen wir die Binomialverteilung $X \sim \text{Binomial}(n, p)$.


- **Wahrscheinlichkeitsfunktion:** $\mathbb{P}(X = x) = \binom{n}{x} p^x (1 - p)^{n-x}$
- Ein Experiment besteht aus n unabhängigen Bernoulli-Trials mit konstanter Erfolgswahrscheinlichkeit p .

Multinomialverteilung

Haben wir **mehr als zwei Kategorien** ($k > 2$), verallgemeinern wir das Ganze zur Multinomialverteilung.

- Eine kategoriale Verteilung hat Wahrscheinlichkeiten $p_1, p_2, \dots, p_k$ mit $\sum p_j = 1$.
- **Wahrscheinlichkeitsfunktion:** $\mathbb{P}(N_1 = n_1, \dots, N_k = n_k) = \frac{n!}{n_1! \dots n_k!} p_1^{n_1} \dots p_k^{n_k}$

Aggregation of Categorical Data



What is the distribution of the vector (#High School, #Bachelor, #Master, #PhD)?

Der Test-Ablauf (Schritt für Schritt)

Schritt 1: Hypothesen aufstellen

- $H_0 : p_1 = p_{1,0}, p_2 = p_{2,0}, \dots, p_k = p_{k,0}$ (Die Daten folgen der angenommenen Verteilung)
- H_1 : Mindestens ein p_i weicht vom angenommenen Wert ab.

Schritt 2: Teststatistik berechnen (Pearson χ^2)

Wir berechnen die gewichtete quadratische Abweichung:

$$\chi^2 = \sum_{i=1}^k \frac{(n_i - E_i)^2}{E_i}$$

- n_i (oder O_i): Beobachtete Anzahl in Kategorie i
- $E_i = n \cdot p_{i,0}$: Erwartete Anzahl in Kategorie i unter H_0

Schritt 3: Entscheidung treffen

Wir vergleichen den berechneten χ^2 -Wert mit dem kritischen Wert der Chi-Quadrat-Verteilung.

- **Freiheitsgrade (df):** $df = k - 1$ (Anzahl der Klassen minus 1)
- **Rejection Region:** Wir lehnen H_0 ab, wenn $\chi_{obs}^2 \geq \chi_{\alpha}^2(k - 1)$.

Damit der Test valide ist, muss die Stichprobe groß genug sein: $E_i = n \cdot p_{i,0} \geq 5$ für alle i . Nur dann ist die Chi-Quadrat-Approximation zuverlässig.

2. Der χ^2 -Unabhängigkeitstest (Independence)

Dieser Test wird verwendet, wenn man zwei qualitative Merkmale (z.B. Geschlecht und Markenbewusstsein) gleichzeitig betrachtet und wissen will, ob diese **voneinander unabhängig** sind.

Die Kontingenztafel (Two-Way Table)

Die Daten werden in einer $r \times c$ Tabelle (Zeilen $\times$ Spalten) angeordnet. Jede Zelle enthält die beobachtete Häufigkeit n_{ij} für eine Kombination beider Merkmale.

Brand Awareness	Male	Female	Totals
Could Identify Product	95	41	136
Could Not Identify Product	50	114	164
Totals	145	155	300

- Let the cell counts be denoted by n_{ij} :

Brand Awareness	Male	Female	Row Totals
Could Identify Product	n_{11}	n_{12}	R_1
Could Not Identify Product	n_{21}	n_{22}	R_2
Column Totals	C_1	C_2	n

- Example: $n_{11} = 95$, $n_{12} = 41$, $n_{21} = 50$, $n_{22} = 114$.

Erwartete Häufigkeiten berechnen

Unter der Annahme der Unabhängigkeit (H_0) berechnet man die erwartete Häufigkeit einer Zelle über die Randsummen:

$$\hat{E}_{ij} = \frac{R_i \cdot C_j}{n}$$

- R_i : Summe der i -ten Zeile
- C_j : Summe der j -ten Spalte
- n : Gesamtzahl der Beobachtungen

Durchführung des Unabhängigkeitstests

Hypothesen

- H_0 : Merkmal A und Merkmal B sind unabhängig.
- H_1 : Merkmal A und Merkmal B sind abhängig.

Teststatistik

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(n_{ij} - E_{ij})^2}{E_{ij}}$$

Freiheitsgrade

Bei einer Tabelle mit r Zeilen und c Spalten gilt:

$$df = (r - 1) \cdot (c - 1)$$


☰ Beispiel: Marketing-Studie

In einer Studie mit 300 Personen ergab sich ein χ^2 -Wert von 46.14. Bei $df = 1$ und $\alpha = 0.05$ ist der kritische Wert 3.841. Da $46.14 > 3.841$, wird H_0 abgelehnt → Geschlecht und Markenbewusstsein hängen zusammen.

3. Die Chi-Quadrat-Verteilung im Detail

Die χ^2 -Verteilung ist ein Spezialfall der Gamma-Verteilung ($\Gamma(\frac{d}{2}, 2)$).

- **Definition:** Wenn $Z_1, \dots, Z_d$ i.i.d. $N(0, 1)$ sind, dann ist $X = \sum Z_i^2 \sim \chi^2(d)$.
- **Erwartungswert:** $\mathbb{E}[X] = d$
- **Varianz:** $Var(X) = 2d$



4. Anwendung in R

Hier sind die wichtigsten Befehle, um diese Tests durchzuführen:

R-Hinweise

- `chisq.test(n_o, p=p0)` führt den Anpassungstest durch.
- `chisq.test(matrix)` führt den Unabhängigkeitstest für eine Kontingenztafel durch.
- Das Argument `correct = FALSE` verhindert die Yates-Stetigkeitskorrektur (oft gewünscht, um Standardergebnisse zu erhalten).

Zusammenfassung der Voraussetzungen

Checkliste für valide Tests

1. **Random Sample:** Die Daten müssen aus einer Zufallsstichprobe stammen.
2. **N-Größe:** Jede erwartete Zelle ≥ 5 .
3. **Unabhängigkeit:** Die einzelnen Trials innerhalb der Stichprobe müssen unabhängig sein.

l12 - Simple linear Regression

Simple Linear Regression (SLR)

Probabilistische vs. Deterministische Modelle

Modellarten

- **Deterministische Modelle:** Beschreiben exakte Beziehungen ohne Fehler (z.B. Physik: $F = m \cdot a, y = \alpha \cdot x$). Für reale Daten (Wirtschaft, Sozialwissenschaften) meist unrealistisch.
- **Probabilistische Modelle:** Berücksichtigen Zufallsschwankungen.

$$Y = \text{Deterministische Komponente} + \text{Zufallskomponente}$$

Ziel der Regression: Modellierung des Erwartungswertes $\mathbb{E}(Y)$, sodass der Fehler $Y - \mathbb{E}(Y)$ minimiert wird.

- **Frage:** Hängen größere Werte einer Variable mit größeren/kleineren Werten einer anderen Variable zusammen? (Korrelation)

Das Simple Linear Regression Modell

Es handelt sich um ein Modell erster Ordnung (Gerade):

SLR Modellgleichung


$$Y = \beta_0 + \beta_1 X + \epsilon$$

- Y : Abhängige Variable (Response variable).
- X : Unabhängige Variable (Predictor / Regressor).
- β_0 : y-Intercept (Schnittpunkt mit der y-Achse).
- β_1 : Slope (Steigung).
- ϵ : Zufälliger Fehlerterm (Random error component).
- **Deterministischer Teil:** $\mathbb{E}(Y|X = x) = \beta_0 + \beta_1 x$

Simple Linear Regression Model

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

- β_0 = y -intercept of the line, that is, the point at which the line intercepts or cuts through the y -axis
- β_1 = slope of the line, that is, the change (amount of increase or decrease) in the deterministic component of y for every **1-unit increase** in x



Fitting the Model: The Least Squares Approach

Da β_0 und β_1 unbekannt sind, müssen sie aus Stichprobendaten $(x_1, y_1), \dots, (x_n, y_n)$ geschätzt werden.

Methode der kleinsten Quadrate (Least Squares - LS):

Wir suchen die Linie $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$, die "am besten" passt.

1. Summe der Fehler ist 0: $\sum (y_i - \hat{y}_i) = 0$.
2. **Sum of Squared Errors (SSE)** wird minimiert:

$$SSE = \sum_{i=1}^n \hat{\varepsilon}_i^2 = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$$

Schätzer für die Parameter

Slope (Steigung):

$$\hat{\beta}_1 = \frac{SS_{xy}}{SS_{xx}}$$

Intercept (Achsenabschnitt):

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Wobei:

- $SS_{xx} = \sum (x_i - \bar{x})^2$
- $SS_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y})$
- $\bar{x}, \bar{y}$ sind die Mittelwerte.

Interpretation der Koeffizienten:


- **Intercept $\hat{\beta}_0$:** Geschätzter Wert von y , wenn $x = 0$. (Oft keine praktische Bedeutung, wenn $x = 0$ außerhalb des Datenbereichs liegt).
- **Slope $\hat{\beta}_1$:** Veränderung von y bei Erhöhung von x um 1 Einheit.

Fitting the Model: The Least Squares Approach

Least Squares Graphically

LS minimizes $\sum_{i=1}^n \hat{\epsilon}_i^2 = \hat{\epsilon}_1^2 + \hat{\epsilon}_2^2 + \dots + \hat{\epsilon}_n^2$, that is

$$(\hat{\beta}_0, \hat{\beta}_1) = \arg \min_{b_0, b_1} \sum_{i=1}^n (y_i - b_0 - b_1 x_i)^2$$



Model Assumptions (Modellannahmen)

Damit wir statistische Inferenz (Tests, Intervalle) betreiben können, nehmen wir folgendes für den Fehlerterm ϵ an:

Annahmen für ϵ_i


$$\epsilon_i \stackrel{iid}{\sim} \mathcal{N}(0, \sigma^2)$$

1. **Normalverteilung:** Fehler sind normalverteilt.
2. **Erwartungswert 0:** $\mathbb{E}(\epsilon_i) = 0$.
3. **Konstante Varianz:** Homoskedastizität (σ^2 ist für alle x gleich).

4. Unabhängigkeit: Fehler ϵ_i und ϵ_j sind unabhängig voneinander.

Model Assumptions

Distribution of Errors



Schätzung der Fehlervarianz σ^2 :

Da wir σ^2 nicht kennen, schätzen wir es mit s^2 (Mean Square Error):

$$\hat{\sigma}^2 = s^2 = \frac{SSE}{n - 2}$$

- $n - 2$ Freiheitsgrade, da 2 Parameter (β_0, β_1) geschätzt wurden.
- Standardfehler der Regression: $s = \sqrt{\frac{SSE}{n-2}}$.

Inferenz: Testen des Slope β_1

Wir wollen wissen: Gibt es einen *linearen* Zusammenhang?

- Falls $\beta_1 = 0 \Rightarrow$ kein linearer Einfluss von x auf y .

Sampling Distribution von $\hat{\beta}_1$:

$$\hat{\beta}_1 \sim \mathcal{N}\left(\beta_1, \frac{\sigma^2}{SS_{xx}}\right)$$

Estimated Standard Error des Slopes:

$$s_{\hat{\beta}_1} = \frac{s}{\sqrt{SS_{xx}}}$$

✓ Hypothesentest für β_1

Hypothesen: $H_0 : \beta_1 = 0$ vs. $H_1 : \beta_1 \neq 0$

Teststatistik:

$$T = \frac{\hat{\beta}_1 - 0}{s_{\hat{\beta}_1}} \sim t(n - 2)$$

Entscheidung:

- Ablehnen, wenn $|T| > t_{\alpha/2}(n - 2)$ (kritischer Wert aus t-Verteilung).
- Oder p-Value $< \alpha$.

Konfidenzintervall für β_1 :

$$\hat{\beta}_1 \pm t_{\alpha/2}(n - 2) \cdot s_{\hat{\beta}_1}$$


Korrelation und Bestimmtheitsmaß

Korrelation (r oder ρ)

Misst Stärke und Richtung des linearen Zusammenhangs.

- **Population:** $\rho = \frac{\text{Cov}(X,Y)}{\sigma_X \sigma_Y}$
- **Stichprobe:** $r = \frac{SS_{xy}}{\sqrt{SS_{xx} SS_{yy}}}$
- Wertebereich: $-1 \leq r \leq 1$.

Reminder: Correlation



Zusammenhang zu Slope:

$$\hat{\beta}_1 = r \cdot \frac{s_y}{s_x}$$

(Vorzeichen von $\hat{\beta}_1$ ist identisch mit Vorzeichen von r).

Bestimmtheitsmaß (R^2)

Misst den Anteil der Varianz in y , der durch das Modell (durch x) erklärt wird.

Coefficient of Determination (R^2)

$$R^2 = \frac{\text{Explained Variability}}{\text{Total Variability}} = 1 - \frac{SSE}{SS_{yy}}$$

- $0 \leq R^2 \leq 1$
- Im Simple Linear Regression Fall gilt: $R^2 = r^2$.
- $R^2 = 1$: Perfekter Fit.
- $R^2 = 0$: x erklärt nichts über y .

Prediction (Vorhersage) und Estimation

Wir nutzen das Modell für zwei verschiedene Dinge:

1. **Mean Response Estimation:** Schätzung des *Erwartungswertes* (Durchschnitts) von Y für ein gegebenes x^* .
 - $\hat{y}(x^*) = \hat{\beta}_0 + \hat{\beta}_1 x^*$
2. **Prediction of Future Observation:** Vorhersage eines *konkreten Einzelwertes* y^* für ein gegebenes x^* .
 - $\hat{y}(x^*) = \hat{\beta}_0 + \hat{\beta}_1 x^*$ (gleicher Punktwert, aber andere Unsicherheit!)

⚠ Unterschied in der Unsicherheit (Standard Error)

1. Für den Mittelwert (Mean Response):

Unsicherheit nur durch Schätzung von β_0, β_1 .

$$s_{\hat{y}(x^*)} = s \sqrt{\frac{1}{n} + \frac{(x^* - \bar{x})^2}{SS_{xx}}}$$

2. Für einen neuen Einzelwert (Prediction):

Unsicherheit durch Schätzung von β_0, β_1 **plus** die Varianz des neuen Fehlers ϵ^* . (Viel breiteres Intervall).


$$s_{(y-\hat{y})} = s \sqrt{1 + \frac{1}{n} + \frac{(x^* - \bar{x})^2}{SS_{xx}}}$$

Hinweis: Der Fehler ist am kleinsten beim Mittelwert $\bar{x}$ und wächst, je weiter x^* davon entfernt ist.

Intervalle $(1 - \alpha)$:

- **Confidence Interval (für Mean):** $\hat{y} \pm t \cdot s_{\hat{y}(x^*)}$
- **Prediction Interval (für Future Obs):** $\hat{y} \pm t \cdot s_{(y-\hat{y})}$

Confidence and Prediction Intervals



Komplettes Beispiel: Feuerschaden

Szenario: Zusammenhang zwischen Feuerschaden (y in 1000€) und Distanz zur Feuerwache (x in Meilen).

- **Daten:** $n = 15$.
- **Fit:** $\hat{y} = 10.278 + 4.919x$.
 - **Interpretation:** Pro Meile Distanz steigt der Schaden um ca. 4919€.
 - Intercept hat keine Bedeutung (Distanz 0 nicht in Daten).
- **Fehleranalyse:** $s = 2.316$ (Die meisten Schäden weichen $\pm 4.64k$ vom Modell ab).
- **Test:** $H_0 : \beta_1 = 0$. $T_{obs} = 12.53$, p-value ≈ 0 . $\rightarrow$ Signifikanter Zusammenhang.
- **Konfidenzintervall Slope (95%):** $(4.070, 5.768)$. Wir sind 95% sicher, dass der wahre Anstieg pro Meile hier liegt.
- **R^2 :** 0.9235. 92% der Varianz im Schaden werden durch die Distanz erklärt. Starker Zusammenhang.

Vorhersage für $x^* = 3.5$ Meilen:

- Punktvorhersage: 27.496 (tausend €).
- Prediction Interval (95%): $(22.324, 32.667)$.
 - Ein **spezifisches** zukünftiges Feuer bei 3.5 Meilen wird mit 95% Wsk. einen Schaden in diesem Bereich haben.

Confidence and Prediction Intervals

